Université Mohammed VI Polytechnique
College of Computing – Benguerir
Filière : Intelligence Artificielle & Data Science

RAPPORT DE STAGE

Projet de Fin d'Année 1 (PFA1)

Schémas de capture de chocs augmentés par apprentissage automatique : de l'imitation à une perte physique déroulée

---

Réalisé au sein de
UM6P – COLLEGE OF COMPUTING
Du 1er juin au 1er août 2026

Réalisé par :
Yasser BAOUZIL

Encadrant professionnel :
M. Radouan BOUKHARFANE

Encadrant académique :
M. Radouan BOUKHARFANE

Année universitaire 2025 – 2026

Remerciements

Je tiens à exprimer ma sincère gratitude à l'ensemble des personnes qui ont rendu ce stage possible et formateur.

Je remercie tout particulièrement M. Radouan Boukharfane, qui a encadré ce stage à la fois sur le plan professionnel et académique, pour m'avoir confié une véritable question de recherche plutôt qu'un cahier des charges figé, pour avoir proposé l'idée centrale de la seconde phase du projet – la fonction de perte physique déroulée – et pour la précision de ses retours, notamment sur la définition correcte du terme BVD, qui a débloqué une étape clé du travail.

Je remercie également le corps professoral et l'administration du College of Computing de l'Université Mohammed VI Polytechnique pour la formation reçue et pour le cadre de travail mis à disposition durant ces deux mois.

Résumé

Ce rapport présente le travail réalisé lors de mon stage de fin d'année (PFA1) au sein du College of Computing de l'Université Mohammed VI Polytechnique. La mission portait sur les schémas numériques de capture de chocs augmentés par apprentissage automatique : déterminer si un réseau de neurones peut améliorer la reconstruction d'un schéma classique de type WENO/TENO pour les lois de conservation hyperboliques.

Le travail s'organise en quatre volets. Le premier reproduit les résultats publiés du schéma WENO5-NN de Stevens & Colonius afin d'établir une référence vérifiée. Le deuxième étend la même approche à TENO5 par entraînement par imitation, et met en évidence un plafond structurel : un réseau entraîné à copier la décision d'un schéma enseignant ne peut, par construction, le dépasser. Ce constat a motivé la seconde phase du stage, fondée sur une *fonction de perte physique déroulée* proposée par l'encadrant : au lieu d'une étiquette d'imitation, le réseau est déroulé sur K pas de simulation réels et évalué directement contre la solution vraie. Cette formulation a exigé une réécriture complète et différentiable du cœur numérique du projet en JAX. Les troisième et quatrième volets appliquent cette perte aux benchmarks scalaires (advection, Burgers) puis au système d'Euler (Sod, Shu–Osher).

Le résultat principal est une victoire nette sur les benchmarks canoniques scalaires ($3{,}5\%$ de gain sur l'advection, $18{,}6\%$ sur Burgers, hors distribution d'entraînement) et une première victoire franche sur le système d'Euler ($1{,}84\%$ sur Shu–Osher), obtenues grâce à un mécanisme de mélange convexe piloté par une tête dédiée. Le second résultat, négatif mais tout aussi instructif, est que le cas de Sod reste une quasi-égalité défavorable au réseau, et qu'un balayage direct du coefficient de mélange démontre qu'il s'agit d'une limite structurelle du schéma appris, non d'un défaut de calibrage.

Mots-clés : schémas WENO/TENO, lois de conservation hyperboliques, capture de chocs, apprentissage profond, différentiation automatique, JAX, perte physique déroulée, système d'Euler.

Table des matières

Remerciements i

Résumé ii

Table des figures v

Liste des tableaux vi

Introduction 1

1 Présentation de l'établissement d'accueil 2

1.1 Domaine d'activité . . . 2

1.2 Structure organisationnelle . . . 2

1.3 Métiers présents . . . 2

2 Contexte scientifique et cadrage du projet 4

2.1 Contexte scientifique : volumes finis et lois de conservation . . . 4

2.2 Reconstructions ENO, WENO et TENO . . . 4

2.3 De l'écoulement réel au signal unidimensionnel . . . 5

2.4 Les problèmes de référence . . . 6

2.4.1 Advection linéaire d'un créneau . . . 7

2.4.2 Équation de Burgers . . . 7

2.4.3 Tube à choc de Sod . . . 7

2.4.4 Problème de Shu–Osher . . . 8

2.5 Travaux connexes . . . 8

2.6 Périmètre, missions et méthodologie . . . 8

3 Conception de la solution 10

3.1 Architecture générale du code . . . 10

3.2 Architecture du réseau classifieur . . . 10

3.3 La fonction de perte physique déroulée . . . 11

3.4 La réécriture différentiable en JAX . . . 11

4 Réalisation et expérimentations 13

4.1 Volet 1 : WENO5-NN vs. WENO5 . . . 13

4.2 Volet 2 : NN-TENO5 par imitation vs. TENO5 . . . 14

4.3 Volet 3 : benchmarks scalaires par perte déroulée 14
4.4 Volet 4 : le système d'Euler 16
4.4.1 Diagnostic et correction de l'instabilité 16
4.4.2 La tête de mélange dédiée 17

5 Résultats, analyse critique et limites 18
5.1 Métriques d'évaluation 18
5.2 Résultats consolidés 18
5.3 Analyse critique 19
5.4 Limites et perspectives 19

Conclusion 21

Références bibliographiques 22

Liste des figures

2.1 Chaîne de calcul complète, illustrée sur un cas réel. (a) Ondes de choc autour d'un T-38 en vol supersonique (photographie schlieren, NASA [11]) et trace de la coupe 1D. (b) Signal $u(x)$ effectivement extrait des pixels le long de cette coupe ; le repère marque la transition la plus raide. (c) Discrétisation en cellules et stencil à 5 points centré sur ce front. (d) Les trois candidats de TENO5 : celui que la discontinuité traverse est écarté ($\delta_k = 0$), les autres sont conservés. Le flux reconstruit alimente ensuite la séparation de Lax–Friedrichs puis l'intégrateur SSPRK3, et la boucle reprend au pas suivant. **Le stage porte exclusivement sur la décision du panneau (d)** ; tous les autres maillons sont identiques entre le schéma classique et le schéma appris. 6

2.2 Tube à choc de Sod. (a) État initial : deux états au repos séparés par une membrane. (b) Structure de la solution à $t > 0$: la rupture engendre simultanément trois ondes de natures différentes – une détente régulière, une discontinuité de contact et un choc. 7

3.1 Architecture du classifieur NN-TENO5 : un stencil normalisé à 5 valeurs X^0 alimente quatre couches cachées ReLU de largeur décroissante (64, 32, 16, 8 neurones) puis une couche sigmoïde, produisant une probabilité de trouble p^k par candidat de TENO5. 10

4.1 Largeur de discontinuité en fonction du temps. Celle de WENO5 croît de façon monotone sous l'effet de la diffusion numérique ; celle du réseau se stabilise autour de $0{,}19$, ce qui explique le gain de $21{,}4\%$ mesuré à $t = 100$. 13

4.2 Équation de Burgers : erreur L_2 en fonction du pas d'espace. Le réseau (orange) passe sous WENO5-JS (bleu) à trois résolutions sur quatre, et repasse légèrement au-dessus autour de $\Delta x \approx 10^{-2}$. 14

4.3 Contributions pondérées des termes de perte au cours de l'entraînement. À gauche, $\mathcal{L}_{\text{TV}}$ brut domine $\mathcal{L}_{\text{MSE}}$ d'environ un facteur 4 et l'entraînement optimise en réalité la mauvaise quantité ; à droite, après normalisation, l'équilibre attendu est rétabli et $\mathcal{L}_{\text{TV}}$ décroît. 15

4.4 Instabilité à l'entraînement sur Euler : la densité maximale diverge d'autant plus vite que la marge de dissipation est augmentée. Ce comportement contre-intuitif écarte la dissipation numérique insuffisante comme cause et oriente le diagnostic vers le traitement des violations de positivité. 16

4.5 Shu–Osher avec tête de mélange dédiée : NN-TENO5euler et TENO5euler sont visuellement quasi identiques face à la référence, NN-TENO5euler étant $1{,}84\%$ plus précis en L_1 moyen sur les trois variables conservées. 17

Liste des tableaux

2.1 Environnement technique du projet. 9

3.1 Composants réécrits dans le module différentiable JAX. 11

5.1 Volet 3 (scalaire), évaluation à l'échelle canonique. NN-TENO5 gagne sur les deux benchmarks, y compris Burgers, explicitement hors distribution d'entraînement. 18

5.2 Volet 4 (Euler), meilleur modèle obtenu (tête de mélange dédiée). Sod est $0{,}35\%$ moins précis ; Shu–Osher est $1{,}84\%$ plus précis – première victoire franche contre un schéma classique sur un benchmark canonique obtenue dans ce projet. . . 18

5.3 Synthèse globale des quatre volets. 19

Introduction

Dans le cadre de ma première année du cycle ingénieur au College of Computing de l'Université Mohammed VI Polytechnique, j'ai effectué un stage de fin d'année de deux mois, du 1er juin au 1er août 2026, au sein de l'établissement même, sous l'encadrement de M. Radouan Boukharfane.

La simulation numérique des écoulements compressibles se heurte à une difficulté ancienne et structurante : en présence d'un choc, une solution discontinue apparaît en temps fini même à partir d'une donnée initiale parfaitement lisse. Un schéma numérique d'ordre élevé appliqué naïvement produit alors des oscillations parasites (phénomène de Gibbs) qui peuvent rendre la solution non physique – densité ou pression négatives – et faire diverger le calcul. Les schémas de la famille ENO/WENO/TENO résolvent ce problème en adaptant localement la reconstruction : ils détectent les sous-stencils traversés par une discontinuité et en réduisent, voire annulent, la contribution.

Cette détection repose sur des indicateurs de régularité analytiques et sur des constantes fixées empiriquement. C'est précisément ce point que l'apprentissage automatique promet d'améliorer : si la décision « garder/écarter » d'un schéma classique est une fonction non linéaire des valeurs locales de la solution, un réseau de neurones peut en principe l'approcher, voire faire mieux. Plusieurs travaux publiés ont exploré cette voie, avec des résultats encourageants mais contrastés.

La question posée à ce stage était donc la suivante : *un réseau de neurones peut-il réellement surpasser un schéma classique de capture de chocs, mesuré contre la solution vraie et sur des benchmarks canoniques ?* Ce rapport répond à cette question en quatre volets expérimentaux, et documente aussi bien les résultats positifs que les échecs, ces derniers ayant orienté de manière décisive la suite du travail.

Le rapport s'organise comme suit. Le chapitre 1 présente l'établissement d'accueil. Le chapitre 2 expose le contexte scientifique, le périmètre du projet et la méthodologie adoptée. Le chapitre 3 décrit la conception de la solution, depuis l'architecture du réseau jusqu'à la réécriture différentiable en JAX. Le chapitre 4 détaille les quatre volets expérimentaux. Le chapitre 5 consolide les résultats et en propose une analyse critique.

Chapitre 1

Présentation de l'établissement d'accueil

1.1 Domaine d'activité

L'Université Mohammed VI Polytechnique (UM6P) est un établissement d'enseignement supérieur et de recherche marocain, implanté principalement sur le campus de Benguerir, dans la région de Marrakech-Safi. Orientée vers la recherche appliquée et l'innovation, elle couvre un large spectre de domaines allant des sciences des matériaux et de l'agriculture aux sciences du numérique.

Le stage s'est déroulé au sein du **College of Computing**, l'une des composantes de l'université, dédiée aux sciences et technologies de l'information : informatique, intelligence artificielle, science des données et calcul scientifique. À la différence d'une entreprise, la finalité première de cette structure n'est pas la production d'un service commercial mais la production de connaissances : publications scientifiques, encadrement doctoral, et développement d'outils et de méthodes réutilisables par la communauté scientifique.

Le projet mené durant ce stage s'inscrit dans l'axe du *calcul scientifique et de la mécanique des fluides numérique* (CFD), à l'intersection de l'analyse numérique classique et de l'apprentissage automatique – un domaine en forte expansion, où les méthodes d'apprentissage sont utilisées non pas pour remplacer les solveurs numériques, mais pour en améliorer des composants ciblés.

1.2 Structure organisationnelle

L'UM6P est organisée en *colleges* et instituts thématiques, chacun regroupant des programmes d'enseignement et des équipes de recherche autour d'un domaine. Le College of Computing suit cette logique : il associe une mission d'enseignement (formations d'ingénieurs, dont la filière Intelligence Artificielle & Data Science que je suis) et une mission de recherche organisée en équipes rattachées à des enseignants-chercheurs.

L'encadrement d'un stagiaire y suit un schéma direct, sans hiérarchie intermédiaire : l'étudiant est rattaché à un enseignant-chercheur qui définit le sujet, oriente le travail et en évalue les résultats. Dans mon cas, M. Radouan Boukharfane a assuré simultanément le rôle d'encadrant professionnel et d'encadrant académique. Cette organisation a une conséquence pratique importante sur le déroulement du stage : le pilotage s'est fait par objectifs scientifiques et par validation de résultats mesurés, plutôt que par jalons de livraison.

1.3 Métiers présents

Les métiers représentés dans l'environnement immédiat du stage relèvent principalement de la recherche et du calcul scientifique :

- **Enseignant-chercheur** – définit les axes de recherche, encadre et publie. C'est le métier de mon encadrant.
- **Doctorant / chercheur postdoctoral** – conduit un programme de recherche sur plusieurs années.

— **Ingénieur de recherche / calcul scientifique** – implémente et optimise les codes de simulation, assure la reproductibilité des expériences.
— **Data scientist / ingénieur en apprentissage automatique** – conçoit, entraîne et évalue les modèles ; profil vers lequel ma formation me destine, et qui correspond à la nature hybride du sujet traité.

Le travail réalisé durant ce stage se situe précisément à l'intersection des deux derniers métiers : il a exigé autant la maîtrise d'un solveur numérique (schémas de reconstruction, intégration temporelle, stabilité) que celle d'une chaîne d'apprentissage (conception d'architecture, fonction de perte, entraînement, évaluation).

Chapitre 2

Contexte scientifique et cadrage du projet

2.1 Contexte scientifique : volumes finis et lois de conservation

Une loi de conservation hyperbolique scalaire s'écrit

$$\partial_t u + \partial_x f(u) = 0,$$

et le système d'Euler compressible en est la généralisation vectorielle, où u regroupe les variables conservées (densité, quantité de mouvement, énergie) et $f(u)$ le flux physique associé. Les deux sont résolus ici par la méthode des lignes : le domaine est divisé en N cellules, chaque cellule i stocke une moyenne u_i, et l'équation est avancée en estimant le flux à chaque interface $i + 1/2$ puis en intégrant

$$\frac{du_i}{dt} = -\frac{1}{\Delta x}\left(\hat{f}_{i+1/2} - \hat{f}_{i-1/2}\right)$$

en temps, à l'aide d'un intégrateur de Runge–Kutta d'ordre trois (SSPRK3). Cet intégrateur a la propriété d'être une combinaison convexe de pas d'Euler explicite, ce qui garantit qu'il n'amplifie pas un état déjà non oscillant. Le flux est par ailleurs séparé en une partie amont et une partie aval (séparation de Lax–Friedrichs) avant reconstruction, afin que le décentrement reste bien défini même là où la vitesse d'onde change de signe.

Toute la difficulté numérique réside dans $\hat{f}_{i+1/2}$: reconstruire une estimation d'ordre élevé à l'interface sans introduire d'oscillations près d'une discontinuité. Pour le système d'Euler, la reconstruction est appliquée non pas aux variables conservées directement, mais aux *champs caractéristiques* du système, obtenus par un changement de base local qui découple les trois ondes. Ce détail a une conséquence importante pour la suite : ce changement de base dépend de la solution elle-même, si bien qu'une reconstruction imparfaite dégrade la base utilisée au pas suivant (section 4.4.1).

2.2 Reconstructions ENO, WENO et TENO

Les trois schémas reconstruisent $\hat{f}_{i+1/2}$ à partir du même stencil à 5 points $f_{i-2}, \ldots, f_{i+2}$, découpé en trois sous-stencils candidats de 3 points qui se chevauchent. Chaque candidat fournit, par interpolation polynomiale, sa propre estimation de la valeur à l'interface. Ce qui distingue les trois schémas est uniquement la *façon* de combiner ces trois estimations.

ENO [1] retient le seul candidat le plus régulier et écarte les deux autres. Ce choix étant discontinu par rapport aux données, il limite l'ordre de précision atteignable dans les régions lisses.

WENO [3] remplace ce choix dur par une combinaison convexe des trois candidats :

$$\hat{f}_{i+1/2} = \sum_{k=0}^{2} w_k \, \hat{f}_{k,i+1/2}, \qquad w_k = \frac{\alpha_k}{\sum_l \alpha_l}, \qquad \alpha_k = \frac{d_k}{(\beta_k + \varepsilon)^q}.$$

Les d_k sont des poids fixes, dits *optimaux*, qui font retrouver la reconstruction complète d'ordre cinq lorsque les trois candidats s'accordent ; ε évite la division par zéro. Chaque β_k est un **indicateur de régularité** : une somme de différences finies au carré qui mesure à quel point le candidat

k est « agité ». Le mécanisme tient en une phrase : près d'une discontinuité, le candidat qu'elle traverse a un β_k grand, donc un poids w_k qui s'effondre vers zéro ; en région lisse, tous les β_k sont petits et comparables, $w_k \to d_k$, et l'ordre cinq est retrouvé.

TENO [5] conserve ce mécanisme mais remplace la pondération progressive par une décision *binaire*. Les β_k sont d'abord normalisés en une mesure $\chi_k \in [0, 1]$, puis comparés à un seuil fixe C_T :

$$\delta_k = \begin{cases} 0, & \text{si } \chi_k < C_T \quad (\text{candidat écarté}) \\ 1, & \text{sinon} \quad (\text{candidat gardé}), \end{cases} \qquad w_k = \frac{d_k\, \delta_k}{\sum_l d_l\, \delta_l}.$$

Un candidat sous le seuil est donc écarté *complètement* plutôt que simplement sous-pondéré. C'est ce qui donne à TENO5 une capture des discontinuités plus nette que WENO5, à coût de calcul comparable, et c'est pourquoi c'est ce schéma que le stage cherche à améliorer.

C'est la décision δ_k que ce stage entraîne un réseau de neurones à remplacer : à partir du stencil normalisé à 5 points, produire pour chacun des trois candidats la probabilité qu'il doive être écarté.

2.3 De l'écoulement réel au signal unidimensionnel

Un choc n'est pas une abstraction mathématique : c'est une discontinuité physique observable. Le panneau (a) de la figure 2.1 en donne une image directe – une photographie schlieren d'un T-38 en vol supersonique à Mach 1,1, prise par la NASA [11]. La technique schlieren rend visibles les gradients de densité de l'air : les bandes sombres obliques sont les ondes de choc attachées à l'appareil.

En prélevant une **coupe unidimensionnelle** à travers cet écoulement (trait rouge), on obtient le signal $u(x)$ du panneau (b) : de longues zones régulières séparées par quelques transitions très raides. C'est exactement la structure que les schémas ENO/WENO/TENO sont conçus pour traiter, et c'est aussi ce qui rend le problème difficile : un schéma d'ordre élevé est excellent sur les zones régulières et catastrophique au voisinage des transitions, où il produit des oscillations parasites.

Tout le travail de ce stage porte donc sur une seule question, posée sur ce signal 1D : *comment reconstruire la valeur à l'interface entre deux cellules, avec un ordre élevé là où le signal est régulier, sans osciller là où il ne l'est pas ?*

La figure 2.1 déroule la chaîne complète sur ce cas réel, depuis l'écoulement physique jusqu'à l'avancement en temps. Les deux premières étapes constituent une mise en place effectuée une seule fois ; les suivantes forment la boucle répétée à chaque pas de temps.

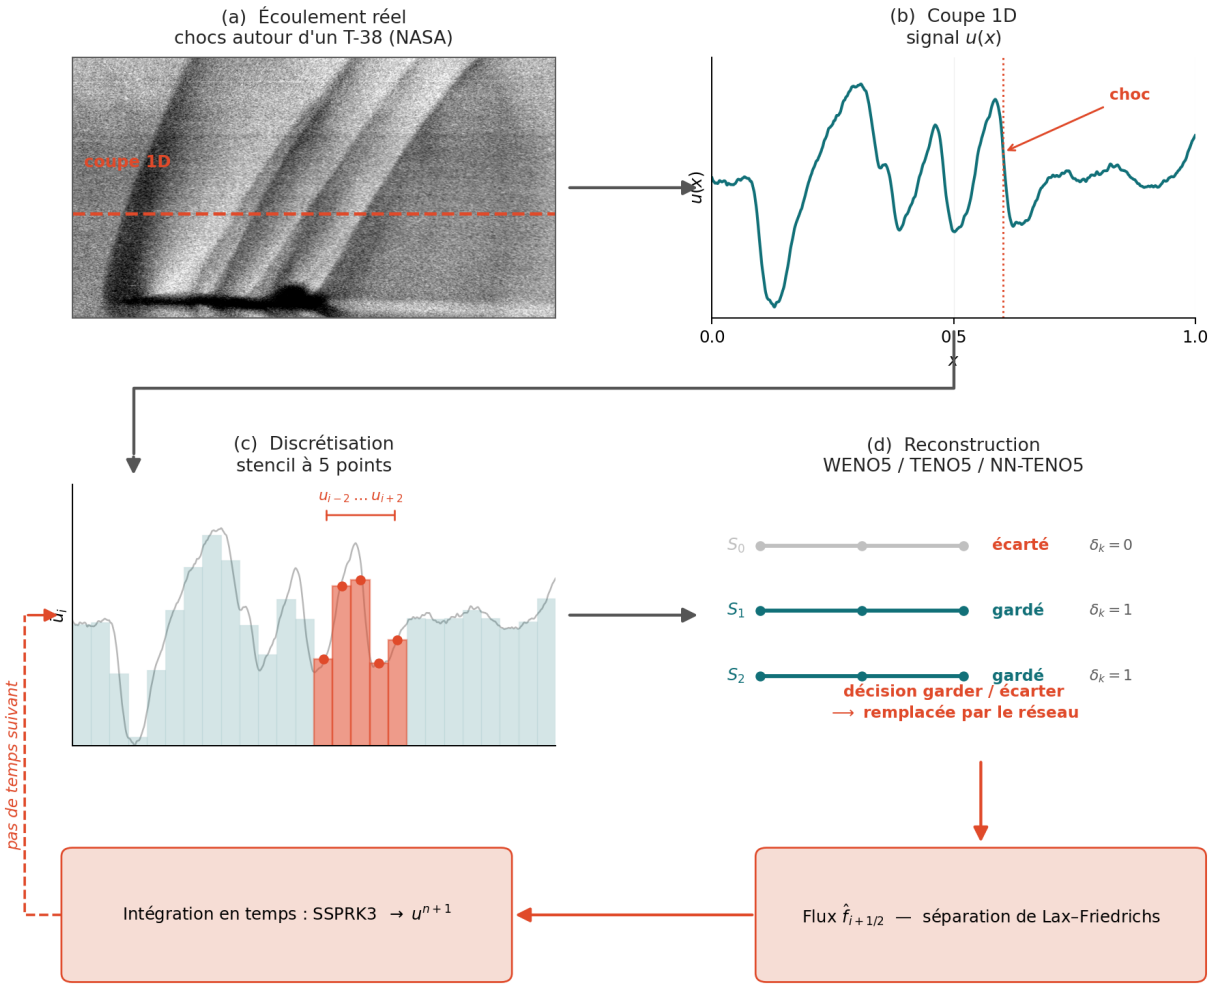


Figure 2.1. Chaîne de calcul complète, illustrée sur un cas réel. (a) Ondes de choc autour d'un T-38 en vol supersonique (photographie schlieren, NASA [11]) et trace de la coupe 1D. (b) Signal $u(x)$ effectivement extrait des pixels le long de cette coupe ; le repère marque la transition la plus raide. (c) Discrétisation en cellules et stencil à 5 points centré sur ce front. (d) Les trois candidats de TENO5 : celui que la discontinuité traverse est écarté ($\delta_k = 0$), les autres sont conservés. Le flux reconstruit alimente ensuite la séparation de Lax–Friedrichs puis l'intégrateur SSPRK3, et la boucle reprend au pas suivant. **Le stage porte exclusivement sur la décision du panneau (d)** ; tous les autres maillons sont identiques entre le schéma classique et le schéma appris.

Le point important est que **le réseau n'intervient qu'à une seule étape**. Il ne remplace ni l'intégrateur temporel, ni la séparation de flux, ni la projection caractéristique : il remplace uniquement la décision de sélection des stencils candidats à l'intérieur de la reconstruction. C'est ce qui rend la comparaison avec le schéma classique équitable – tous les autres maillons sont rigoureusement identiques entre les deux – et c'est aussi ce qui impose la contrainte technique centrale du projet : pour entraîner le réseau contre le résultat obtenu *après* plusieurs pas de temps, toute la chaîne en aval de la reconstruction doit être différentiable (section 3.4).

2.4 Les problèmes de référence

Quatre problèmes canoniques servent de banc d'essai dans tout ce rapport. Ils sont choisis parce qu'ils isolent chacun une difficulté différente, et parce qu'ils disposent tous d'une solution exacte ou d'une référence finement convergée permettant une mesure d'erreur non ambiguë.

2.4.1 Advection linéaire d'un créneau

L'équation $\partial_t u + a\,\partial_x u = 0$ transporte le profil initial sans le déformer : la solution exacte à l'instant t est simplement $u_0(x - at)$. Toute déformation observée est donc *entièrement* imputable au schéma numérique, ce qui en fait le test le plus propre qui soit. Avec un créneau comme donnée initiale, le défaut mesuré est la **diffusion numérique** : à chaque pas, le schéma élargit légèrement les deux fronts. Sur un temps long, cet élargissement s'accumule – c'est exactement ce que montre la figure 4.1 du chapitre 4.

2.4.2 Équation de Burgers

L'équation $\partial_t u + \partial_x(u^2/2) = 0$ ajoute la **non-linéarité** : le flux dépend de la solution elle-même, si bien qu'une donnée initiale parfaitement lisse développe un choc en temps fini. Ce problème teste donc la capacité du schéma à traiter une discontinuité qu'il n'a pas reçue en entrée mais qu'il a lui-même vue se former. Dans ce rapport, il joue un rôle supplémentaire : la fonction de flux $u^2/2$ étant absente du jeu d'entraînement d'origine, Burgers constitue un test explicite **hors distribution**.

2.4.3 Tube à choc de Sod

Le problème de Sod [9] est le cas test de référence du système d'Euler. Sa donnée initiale est une simple discontinuité entre deux états au repos (figure 2.2a), comme si une membrane séparant un gaz comprimé d'un gaz détendu était rompue à $t = 0$.

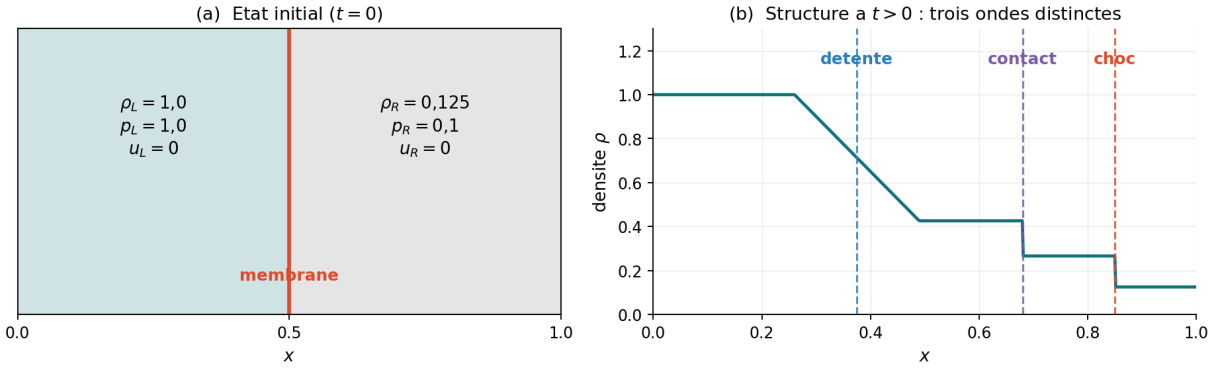


Figure 2.2. Tube à choc de Sod. (a) État initial : deux états au repos séparés par une membrane. (b) Structure de la solution à $t > 0$: la rupture engendre simultanément trois ondes de natures différentes – une détente régulière, une discontinuité de contact et un choc.

Sa difficulté tient à ce que la rupture engendre *simultanément trois ondes de natures différentes* (figure 2.2b) :

- une **onde de détente**, régulière et étalée, que le schéma doit résoudre avec son ordre élevé ;
- une **discontinuité de contact**, où la densité saute mais où la pression et la vitesse restent continues – c'est l'onde la plus difficile à maintenir nette, car rien dans la dynamique ne s'oppose à sa diffusion ;
- un **choc**, discontinuité franche, que le schéma doit capturer sans osciller.

Un bon schéma doit donc être simultanément précis, non diffusif et non oscillant, sur trois structures qui appellent des comportements opposés. C'est précisément parce que Sod est *déjà très bien traité* par TENO5 qu'il s'est révélé, dans ce projet, le problème le plus résistant à l'amélioration par apprentissage (section 4.4).

2.4.4 Problème de Shu–Osher

Le problème de Shu–Osher est un choc se propageant dans un champ de densité sinusoïdal. Il combine ainsi, dans un même calcul, une **discontinuité forte** et des **structures fines oscillantes** – une situation représentative de l'interaction choc/turbulence.

La difficulté ne vient pas du choc lui-même, qui est capturé sans peine, mais des oscillations de haute fréquence situées juste derrière lui : un schéma trop dissipatif les écrase (voir la figure 4.5 au chapitre 4). C'est précisément la marge sur laquelle un schéma appris peut espérer gagner, et c'est bien sur ce problème que la seule victoire franche du projet sur le système d'Euler a été obtenue.

Ce contraste entre Sod et Shu–Osher – un problème où le schéma classique est déjà quasi optimal, un autre où il laisse une marge dissipative – constitue l'un des résultats structurants du rapport, et il est analysé en section 4.4.

2.5 Travaux connexes

Trois directions publiées structurent ce travail.

Stevens & Colonius [6] entraînent un réseau à *corriger* la reconstruction de WENO5 plutôt qu'à la produire de zéro : le réseau part du résultat du schéma classique et n'apprend que l'écart à lui appliquer. Biaiser ainsi le réseau vers un point de départ déjà bon a été, selon les auteurs, le changement qui a rendu l'entraînement stable. C'est un raisonnement que ce projet réutilise directement, à deux reprises : pour le pré-entraînement par imitation (section 4.3) et pour le mécanisme de mélange convexe (section 4.4).

Fu, Hu & Adams [5] introduisent le schéma TENO, dont ce stage cherche à améliorer la décision de sélection.

Li, Fu & Adams [7] proposent NENO6, qui entraîne un réseau *classifieur* prédisant une probabilité « à problème / à garder » par candidat. Son architecture est celle que reprend le classifieur NN-TENO5 de ce stage.

2.6 Périmètre, missions et méthodologie

Le sujet, tel qu'énoncé sur la fiche technique du stage, était « *Machine learning-based numerical scheme for CFD* », avec trois missions : une revue de littérature, la construction d'un réseau de neurones calculant les fonctions de pondération d'un schéma de type WENO, et l'évaluation de ses performances.

Le périmètre a été volontairement restreint aux problèmes **unidimensionnels** (advection linéaire, équation de Burgers, système d'Euler) et aux schémas d'ordre cinq (WENO5, TENO5). Les extensions multidimensionnelles et les ordres supérieurs (WENO3/WENO7, TENO3/TENO7) ont été écartés faute de temps, et sont discutés comme perspectives.

Le travail s'appuie sur un code source existant en accès libre implémentant l'article WENO5-NN. Plutôt que de repartir de zéro, il l'étend à TENO5, en reproduit d'abord les résultats publiés comme référence, puis teste une méthodologie d'entraînement absente des travaux publiés.

Méthodologie de travail

Le sujet étant une question de recherche plutôt qu'un cahier des charges figé, le travail a été organisé comme une **séquence d'expériences falsifiables** plutôt que comme un plan d'implémentation linéaire : chaque phase propose un mécanisme précis, le teste contre la solution vraie, et le conserve, le corrige ou l'abandonne selon le résultat mesuré.

Deux critères d'évaluation ont été appliqués uniformément à toutes les expériences :

- `beats_teacher` : l'erreur du réseau contre la solution vraie est strictement inférieure à celle du schéma classique contre cette même solution. **C'est le seul critère utilisé pour revendiquer une victoire dans ce rapport.**
- `teacher_fidelity` : l'erreur du réseau est à moins de 2% de celle du schéma classique. Ce critère plus permissif n'a servi qu'à des tests d'acceptation précoces et n'est jamais utilisé comme preuve de supériorité.

Chaque expérience a été mesurée sur des benchmarks canoniques (hors données d'entraînement) et documentée immédiatement, y compris lorsqu'elle dégradait les résultats. C'est pourquoi le journal d'expériences interne du projet recense 21 phases plutôt qu'une poignée de succès sélectionnés : plusieurs correctifs corrects sur le papier se sont révélés mesurablement nuisibles et ont dû être annulés. Une seconde règle méthodologique, adoptée après la perte d'un point de sauvegarde fonctionnel, a été de committer et sauvegarder chaque bon résultat vérifié avant d'entamer l'expérience suivante.

Le tableau 2.1 récapitule l'environnement technique utilisé.

Catégorie	**Outils**
Langage	Python 3
Calcul numérique	NumPy, SciPy
Apprentissage (phase 1)	TensorFlow / Keras
Apprentissage différentiable (phase 2)	JAX, Optax
Visualisation	Matplotlib
Gestion de version	Git
Rédaction	LaTeX (XeLaTeX)

Table 2.1. Environnement technique du projet.

Chapitre 3

Conception de la solution

3.1 Architecture générale du code

Le projet est organisé en modules séparant strictement les schémas numériques, les réseaux, et la couche différentiable :

- `src/schemes/` – implémentations NumPy déterministes de WENO5 et TENO5, servant à la fois de schémas de référence et d'enseignants pour l'entraînement par imitation.
- `src/networks/` – définitions des réseaux (Keras) et fonctions d'entraînement par imitation.
- `src/core/` – solveur : intégration temporelle, séparation de flux, conditions aux limites.
- `src/differentiable/` – réécriture JAX complète et différentiable du cœur numérique (section 3.4).
- `scripts/` – scripts d'entraînement, d'évaluation et de génération de figures.

3.2 Architecture du réseau classifieur

Le réseau NN-TENO5 est un perceptron multicouche à cinq couches de poids, suivant l'architecture de NENO6 [7] : un stencil normalisé à 5 valeurs en entrée, quatre couches cachées ReLU de largeur décroissante (64, 32, 16, 8), et une couche sigmoïde produisant une probabilité de trouble par candidat de TENO5. La figure 3.1 en donne la structure détaillée.

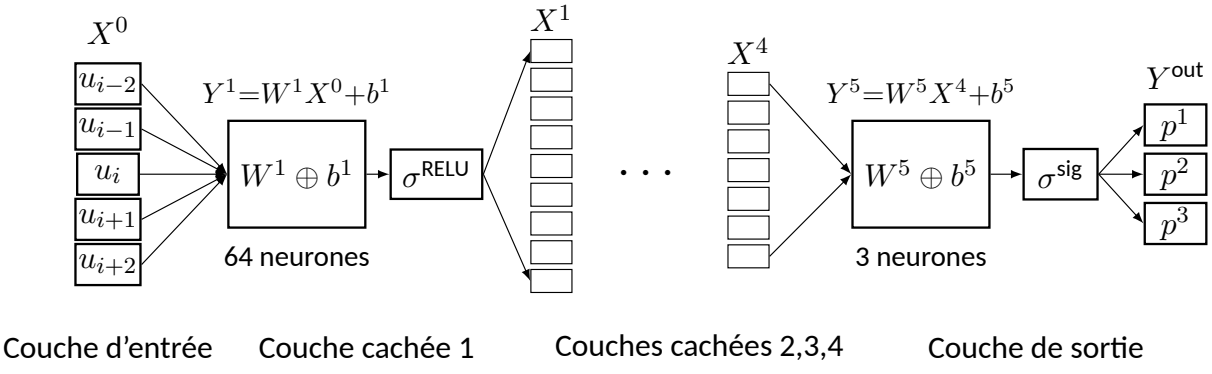


Figure 3.1. Architecture du classifieur NN-TENO5 : un stencil normalisé à 5 valeurs X^0 alimente quatre couches cachées ReLU de largeur décroissante (64, 32, 16, 8 neurones) puis une couche sigmoïde, produisant une probabilité de trouble p^k par candidat de TENO5.

Chaque couche l calcule l'application affine $X^{l-1} \to Y^l = W^l X^{l-1} + b^l$, suivie d'une activation :

$$\sigma^{\text{RELU}}(x) = \max(x, 0), \qquad \sigma^{\text{sig}}(x) = \frac{1}{1 + e^{-x}}.$$

La sortie $[p^1, p^2, p^3]$ se lit comme la probabilité que chaque candidat soit traversé par une discontinuité. À l'inférence, un candidat est écarté dès que sa probabilité dépasse $0{,}5$; pendant

l'entraînement par perte déroulée, ce seuil dur est remplacé par la probabilité continue elle-même, afin que les gradients puissent traverser la décision.

3.3 La fonction de perte physique déroulée

L'entraînement par imitation présente une limite structurelle : sa fonction de perte ne mesure que la distance à la décision de *l'enseignant*, jamais la distance à la solution *vraie*. Un réseau ne peut être poussé vers une réponse qu'on ne lui montre jamais.

L'encadrant a proposé une alternative, la **fonction de perte physique déroulée** : au lieu d'une étiquette d'imitation ponctuelle, le réseau est utilisé pour avancer réellement la simulation sur K pas de temps, et la perte est calculée directement contre la solution vraie K pas plus tard. Elle combine plusieurs termes, dont les trois principaux sont :

$$\mathcal{L}_{\text{total}} = \lambda_1 \mathcal{L}_{\text{MSE}} + \lambda_2 \mathcal{L}_{\text{TV}} + \lambda_3 \mathcal{L}_{\text{Reg}} + \dots$$

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^{N} \left(u_i^{n+K} - u_{i,\text{exact}}^{n+K} \right)^2, \qquad \mathcal{L}_{\text{TV}} = \max\left(0,\ \text{TV}(u^{n+K}) - \text{TV}(u^n)\right).$$

Le premier, $\mathcal{L}_{\text{MSE}}$, mesure l'écart à la solution vraie après K pas – c'est le terme central, celui qui rend l'approche différente de l'imitation. Le deuxième pénalise toute augmentation de la variation totale $\text{TV}(v) = \sum_i |v_{i+1} - v_i|$, c'est-à-dire toute apparition d'oscillations parasites. Le troisième, $\mathcal{L}_{\text{Reg}}$, ancre la solution du réseau sur celle du schéma classique et l'empêche de s'en écarter arbitrairement. S'y ajoute un terme de cohérence entre cellules voisines (principe *Boundary Variation Diminishing*, ou BVD [5]) : à une interface donnée, la cellule de gauche et celle de droite proposent chacune une valeur, et ce terme pénalise leur désaccord. Enfin, pour le système d'Euler, un dernier terme pénalise les états non physiques – densité ou pression négatives (section 4.4.1).

3.4 La réécriture différentiable en JAX

Cette formulation ne pouvait pas être testée dans le code d'origine : dérouler K pas de simulation exige que *toute* la chaîne – reconstruction, séparation de flux, intégration temporelle, projection caractéristique – soit différentiable de bout en bout. Or le solveur NumPy ne porte aucun gradient, et `model.predict()` de Keras se détache entièrement du graphe.

Le module `src/differentiable/` est donc une réécriture JAX complète du cœur numérique, et non une simple enveloppe. Le tableau 3.1 résume les composants réimplémentés.

Composant	Contenu réimplémenté en JAX
Reconstruction	TENO5 complet : β_k, τ_5, seuillage, renormalisation
Solveur	SSPRK3, séparation de Lax–Friedrichs, conditions aux limites
Euler	base propre de Roe, projection caractéristique, réparation de positivité
Réseau	propagation avant du MLP, sans dépendance à Keras
Perte	les cinq termes, dont la pénalité de positivité d'Euler

Table 3.1. Composants réécrits dans le module différentiable JAX.

Le seuillage binaire de TENO5 pose ici une difficulté spécifique : la fonction δ_k a une dérivée nulle presque partout, ce qui bloquerait toute rétropropagation. C'est pourquoi la probabilité continue du réseau remplace le seuil dur pendant l'entraînement.

Chapitre 4

Réalisation et expérimentations

4.1 Volet 1 : WENO5-NN vs. WENO5

Le premier volet reproduit les trois configurations publiées par Stevens & Colonius [6], à partir de leur jeu d'entraînement d'origine (75 241 échantillons), afin d'établir une référence vérifiée.

Advection d'un créneau. WENO5-NN réduit l'erreur L_1 de $28{,}7\%$, L_2 de $17{,}1\%$, L_∞ de $5{,}2\%$ et la largeur de choc de $21{,}4\%$ face à WENO5 : le résultat le plus net des trois cas. La figure 4.1 explique ce gain : la largeur de la discontinuité produite par WENO5 croît continûment sous l'effet de la diffusion numérique, tandis que celle du réseau se stabilise.

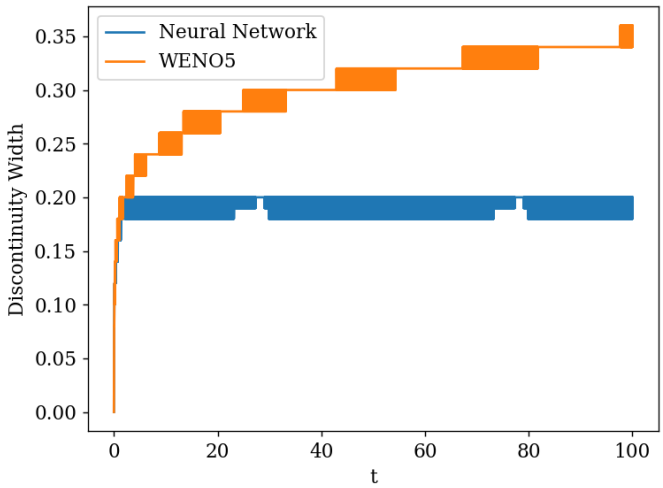


Figure 4.1. Largeur de discontinuité en fonction du temps. Celle de WENO5 croît de façon monotone sous l'effet de la diffusion numérique ; celle du réseau se stabilise autour de $0{,}19$, ce qui explique le gain de $21{,}4\%$ mesuré à $t = 100$.

Équation de Burgers. Résultat franchement mitigé : le réseau gagne à 3 des 4 résolutions testées et perd à la quatrième (figure 4.2). Cela rejoint l'observation des auteurs eux-mêmes : les deux schémas se comportent de façon similaire pour un vrai choc, l'avantage du réseau venant surtout de la région lisse pré-choc.

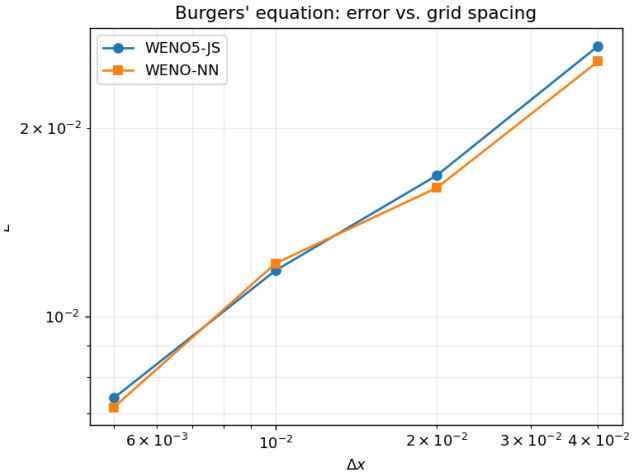


Figure 4.2. Équation de Burgers : erreur L_2 en fonction du pas d'espace. Le réseau (orange) passe sous WENO5-JS (bleu) à trois résolutions sur quatre, et repasse légèrement au-dessus autour de $\Delta x \approx 10^{-2}$.

Sod et Shu–Osher. Quasi-égalité : les courbes sont visuellement indiscernables de la solution exacte. C'est néanmoins une défaite sous le critère strict, l'erreur L_∞ du réseau étant supérieure de $0{,}265\%$ pour Sod et $0{,}551\%$ pour Shu–Osher.

Le verdict du volet 1 est donc une **égalité fortement dépendante du problème** : une victoire nette là où la distribution d'entraînement du réseau correspond bien au problème, et une quasi-égalité défavorable sur les cas qui la sollicitent davantage.

4.2 Volet 2 : NN-TENO5 par imitation vs. TENO5

Le deuxième volet applique la même idée à TENO5, avec le classifieur décrit en section 3.2, entraîné à reproduire la décision garder/écarter de TENO5.

Par construction, un réseau entraîné uniquement à imiter un enseignant ne peut pas dépasser la qualité de reconstruction de celui-ci, sauf par son propre bruit de généralisation. Les mesures le confirment : sur 3 des 4 benchmarks scalaires testés, NN-TENO5 produit une égalité *exacte* avec TENO5 ; sur l'advection d'un créneau, il perd de $0{,}64\%$; sur les benchmarks d'Euler, il produit deux petites victoires compatibles avec le plafond d'imitation (reproduire ou perturber très légèrement la décision de l'enseignant peut occasionnellement tomber plus près de la solution vraie par hasard, sans amélioration systématique).

Deux tentatives de dépassement à l'intérieur du paradigme d'imitation – entraînement sur cible exacte, extension à un stencil WENO7 à 7 points, recherche d'hyperparamètres étendue, et entraînement sur données TENO5 « réétiquetées par oracle » – ont toutes produit soit un résultat négatif, soit une petite victoire plafonnant au même niveau. Ce constat, **le plafond est structurel au paradigme d'imitation lui-même, non un défaut de réglage**, a directement motivé la seconde phase du stage.

4.3 Volet 3 : benchmarks scalaires par perte déroulée

La perte déroulée a d'abord été testée sur l'advection et Burgers. Trois obstacles ont dû être levés successivement.

Obstacle 1 – déséquilibre des termes de perte. Entraîner en suivant littéralement les équations de la proposition, avec $\mathcal{L}_{\text{TV}}$ et $\mathcal{L}_{\text{Reg}}$ non normalisés, laisse le gradient de $\mathcal{L}_{\text{TV}}$ dominer celui de $\mathcal{L}_{\text{MSE}}$ d'un facteur ≈ 4, même après application de son poids $0{,}1$. La figure 4.3 montre le diagnostic et l'effet du correctif (normalisation en moyenne plutôt qu'en somme).

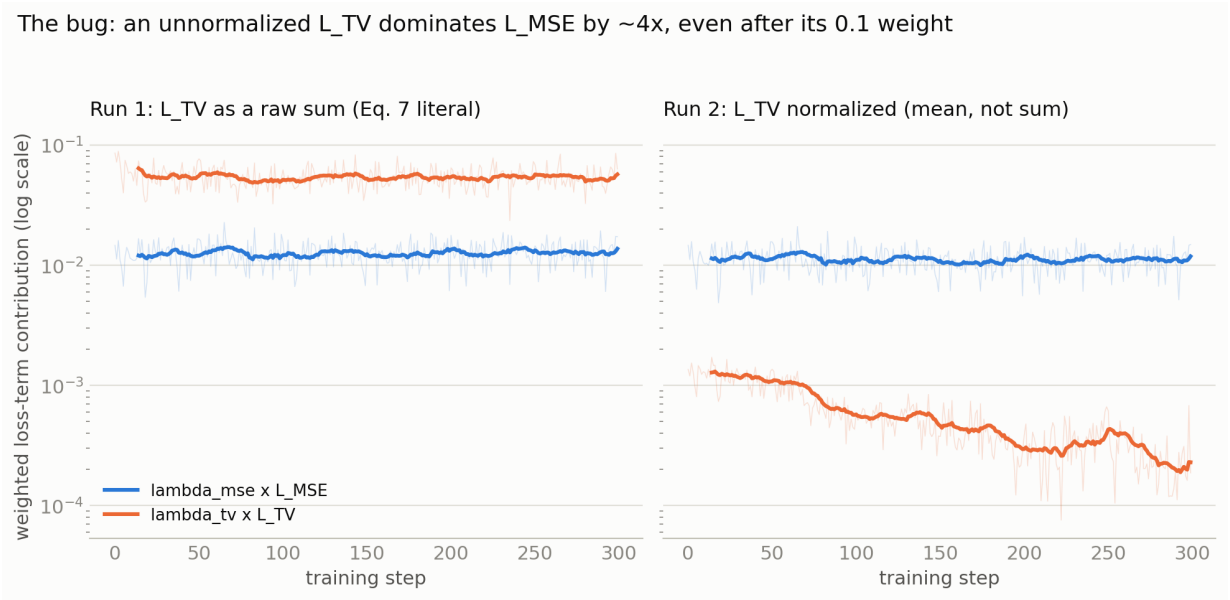


Figure 4.3. Contributions pondérées des termes de perte au cours de l'entraînement. À gauche, $\mathcal{L}_{\text{TV}}$ brut domine $\mathcal{L}_{\text{MSE}}$ d'environ un facteur 4 et l'entraînement optimise en réalité la mauvaise quantité ; à droite, après normalisation, l'équilibre attendu est rétabli et $\mathcal{L}_{\text{TV}}$ décroît.

Obstacle 2 – initialisation. Entraîner un réseau initialisé aléatoirement directement contre la perte déroulée échoue complètement. Le correctif reprend le motif déjà validé au volet 2 : pré-entraînement par imitation, puis affinage par perte déroulée.

Obstacle 3 – généralisation. Le réseau obtenu gagnait 2 des 3 tests tenus à l'écart, mais ne généralisait ni au benchmark canonique à pleine échelle, ni au flux non linéaire de Burgers, absent de sa distribution d'entraînement.

Le correctif final réutilise un mécanisme développé d'abord pour le système d'Euler (section 4.4) : une **tête de mélange** entraînée séparément, produisant un coefficient de combinaison convexe $\lambda \in [0, 1]$ entre la reconstruction de TENO5 et celle du réseau :

$$u_{\text{final}} = (1 - \lambda)\, u_{\text{TENO5}} + \lambda\, u_{\text{réseau}},$$

complété par des exemples d'entraînement à flux de Burgers. Ce mécanisme garantit que le réseau ne peut qu'interpoler *vers* sa propre reconstruction depuis celle de TENO5, jamais la dépasser dans la mauvaise direction.

Deux observations méritent d'être soulignées. D'abord, la tête *non entraînée* (avec un biais initial conservateur donnant $\lambda \approx 4{,}7\%$ uniformément) gagnait déjà sur les deux benchmarks canoniques *avant tout entraînement supplémentaire*. Ensuite, et de façon contre-intuitive, **le mélange uniforme bat le mélange concentré sur les stencils à problème** : laisser le réseau corriger aussi les petites erreurs du schéma classique en région lisse apporte davantage que de le cantonner aux zones que le schéma classique signale.

4.4 Volet 4 : le système d'Euler

Le système d'Euler est plus difficile pour deux raisons indépendantes : la reconstruction y est couplée et caractéristique (section 2.1), et la solution doit rester physiquement valide (densité et pression positives) à *chaque* étape intermédiaire de l'entraînement, pas seulement à convergence.

4.4.1 Diagnostic et correction de l'instabilité

La première tentative d'entraînement a divergé purement et simplement : les valeurs d'état croissaient sans borne en quelques sous-pas SSPRK3, quelle que soit l'augmentation de la marge de dissipation de la séparation de Lax–Friedrichs. La figure 4.4 montre le résultat décisif : *augmenter* la dissipation fait arriver l'instabilité *plus vite*, ce qui écarte l'hypothèse d'un choc sous-résolu et oriente vers un bogue.

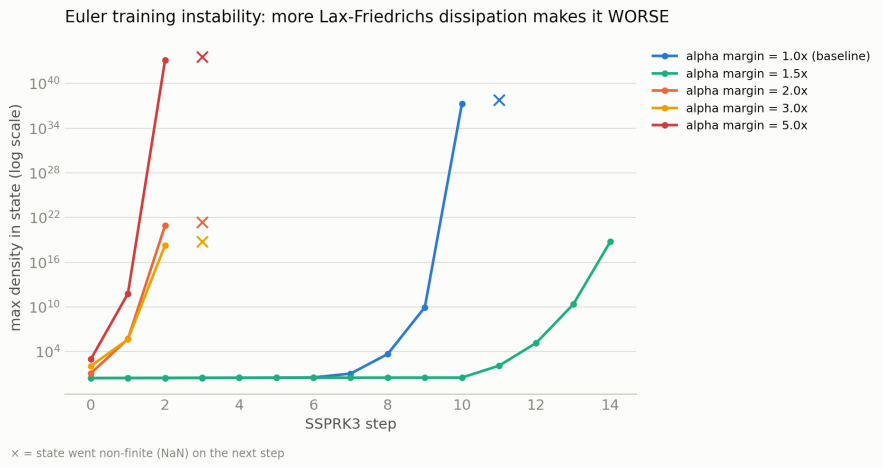


Figure 4.4. Instabilité à l'entraînement sur Euler : la densité maximale diverge d'autant plus vite que la marge de dissipation est augmentée. Ce comportement contre-intuitif écarte la dissipation numérique insuffisante comme cause et oriente le diagnostic vers le traitement des violations de positivité.

Deux défauts concrets ont été identifiés et corrigés :

1. **Une pénalité de positivité structurellement inerte.** Le terme censé pénaliser les états non physiques était calculé sur l'état final *déjà réparé* de chaque pas, après application d'un écrêtage : il ne pouvait donc mathématiquement jamais être non nul. Corrigé en calculant la pénalité sur les sous-étapes avant réparation.
2. **Un mécanisme de réparation incomplet.** La réparation ne testait que le signe ; elle ne détectait ni les valeurs non finies (`NaN`/`Inf`) ni les magnitudes non bornées, qui peuvent naître d'une reconstruction imparfaite réinjectée dans la base propre de Roe du pas suivant. Corrigé par l'ajout de tests explicites de finitude et de magnitude.

Combinés à la clarification de la définition du terme BVD apportée par l'encadrant, ces correctifs ont produit le premier entraînement d'Euler qui ne diverge pas.

4.4.2 La tête de mélange dédiée

Le mécanisme qui a finalement produit une victoire canonique est le mélange convexe introduit en section 4.3, mais son coefficient λ devait être calculé par une tête *dédiée*, entraînée séparément, plutôt que réutilisé depuis la sortie de probabilité de trouble du réseau. Réutiliser ce signal faisait porter à λ deux rôles incompatibles – signaler un problème *et* calibrer la confiance accordée au réseau – et a causé trois régressions distinctes. Une petite tête entraînée spécifiquement, initialisée de façon conservatrice (biais $= -3$, soit $\lambda \approx 4{,}7\%$ au départ), a corrigé ce point et produit la première victoire canonique franche du projet (figure 4.5).

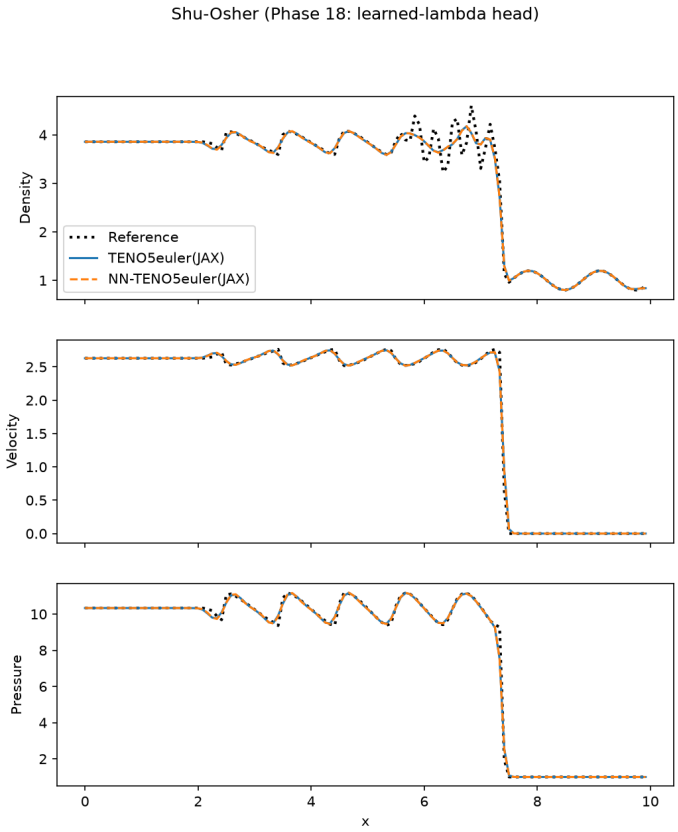


Figure 4.5. Shu–Osher avec tête de mélange dédiée : NN-TENO5euler et TENO5euler sont visuellement quasi identiques face à la référence, NN-TENO5euler étant $1{,}84\%$ plus précis en L_1 moyen sur les trois variables conservées.

Le cas de Sod, en revanche, est resté une quasi-égalité légèrement défavorable au réseau même après ce correctif. Deux tentatives supplémentaires – un taux d'apprentissage 50 fois plus élevé pour la seule tête de mélange, et une porte enrichie voyant le stencil brut plutôt que le seul résumé de probabilité – n'ont déplacé le ratio de Sod que marginalement ($1{,}0045\times$, puis $1{,}0026\times$), jamais au-delà de la parité.

Un balayage direct d'un coefficient λ fixe (non appris) a confirmé qu'il s'agit d'une **limite structurelle** du schéma appris sur Sod, et non d'un défaut de calibrage : l'erreur de Sod croît de façon *monotone* avec chaque λ testé de 0 à $0{,}3$, tandis que celle de Shu–Osher *décroît* de façon monotone jusqu'à $\lambda \approx 0{,}2$ sur le même balayage. Aucun réglage de la porte ne peut corriger un schéma de base qui est, sur ce problème précis, simplement moins précis que TENO5.

Chapitre 5

Résultats, analyse critique et limites

5.1 Métriques d'évaluation

Tous les résultats sont mesurés avec le même jeu de métriques, appliqué identiquement au schéma classique et au réseau. Avec $d_i = u_i - u_i^{\text{ref}}$:

$$L_1 = \frac{1}{N}\sum_i |d_i|, \qquad L_2 = \sqrt{\frac{1}{N}\sum_i d_i^2}, \qquad L_\infty = \max_i |d_i|.$$

Pour Euler, elles sont calculées indépendamment par variable conservée (densité, quantité de mouvement, énergie) puis moyennées en un scalaire $\bar{L}_1$. Trois diagnostics complémentaires sont utilisés : la variation totale $\mathrm{TV}(u) = \sum_i |u_{i+1} - u_i|$ (dont un excès signale une oscillation parasite), la positivité ($\min_i \rho_i > 0$ et $\min_i p_i > 0$), et l'erreur de localisation du choc et du contact.

5.2 Résultats consolidés

Les tableaux 5.1 et 5.2 consolident les mesures finales, et le tableau 5.3 résume les quatre volets.

Benchmark	TENO5	NN-TENO5 (JAX)	Ratio	Verdict
Advection (L_1)	3,4819e-02	3,3813e-02	$0{,}9711\times$	**VICTOIRE**
Advection (L_2)	9,8960e-02	9,5521e-02	$0{,}9653\times$	**VICTOIRE**
Burgers (L_1, hors distribution)	2,0697e-04	1,7873e-04	$0{,}8636\times$	**VICTOIRE**
Burgers (L_2, hors distribution)	8,1670e-04	6,6493e-04	$0{,}8142\times$	**VICTOIRE**

Table 5.1. Volet 3 (scalaire), évaluation à l'échelle canonique. NN-TENO5 gagne sur les deux benchmarks, y compris Burgers, explicitement hors distribution d'entraînement.

Benchmark	TENO5euler $\bar{L}_1$	NN-TENO5euler $\bar{L}_1$	Ratio	Verdict
Sod	8,2583e-03	8,2871e-03	$1{,}0035\times$	DÉFAITE
Shu–Osher	2,1319e-01	2,0926e-01	$0{,}9816\times$	**VICTOIRE**

Table 5.2. Volet 4 (Euler), meilleur modèle obtenu (tête de mélange dédiée). Sod est $0{,}35\%$ moins précis ; Shu–Osher est $1{,}84\%$ plus précis – première victoire franche contre un schéma classique sur un benchmark canonique obtenue dans ce projet.

Volet	Verdict	Résultat	Observation principale
1. WENO5-NN vs. WENO5	Fortement dépendant du problème	ÉGALITÉ	Victoire sur l'advection et 3/4 résolutions de Burgers ; légère défaite sur Sod et Shu–Osher.
2. NN-TENO5 (imitation)	Reproduit son enseignant	ÉGALITÉ	Trois égalités exactes, deux petites victoires Euler, une défaite sur l'advection.
3. NN-TENO5 (perte déroulée), scalaire	Victoire sur les deux benchmarks	**VICTOIRE**	$3{,}5\%$ sur l'advection, $18{,}6\%$ sur Burgers (hors distribution).
4. NN-TENO5euler (perte déroulée)	Première victoire canonique	**VICTOIRE**	$1{,}84\%$ sur Shu–Osher ; Sod reste une quasi-égalité structurelle.

Table 5.3. Synthèse globale des quatre volets.

5.3 Analyse critique

Deux résultats se dégagent, et ce sont les deux faces d'une même observation : **la manière dont un réseau est entraîné compte davantage que son architecture**.

Le premier est le plafond d'imitation du volet 2. Un réseau entraîné à copier un enseignant hérite de ses limites ; aucune quantité de réglage d'hyperparamètres, d'élargissement du stencil ou de réétiquetage n'a permis de le franchir. Le second est le succès des volets 3 et 4 : en changeant le *signal* d'entraînement – une perte mesurée contre la solution vraie après K pas réels, plutôt que contre la décision d'un enseignant – le même type de réseau devient capable de dépasser le schéma classique, y compris sur un flux absent de sa distribution d'entraînement.

Trois réserves doivent cependant accompagner ces résultats.

Les gains sont modestes et non uniformes. $1{,}84\%$ sur Shu–Osher est une victoire réelle mais faible, et Sod reste défavorable. Le balayage de λ montre que le comportement est de signe opposé sur les deux problèmes, ce qui suggère que le schéma appris n'améliore pas la reconstruction de façon universelle, mais seulement sur certaines structures d'écoulement.

Le coût de calcul n'est pas compensé. Chaque variante neuronale s'exécute nettement plus lentement par cellule que son équivalent classique – environ 5 à $18\times$ pour les modèles fondés sur Keras. Les gains de précision rapportés ne constituent donc pas, en l'état, un avantage calcul/précision.

Le mécanisme gagnant est un garde-fou. La tête de mélange convexe garantit que le réseau ne peut qu'interpoler vers sa propre reconstruction sans la dépasser. C'est ce qui rend le résultat robuste, mais cela borne aussi mécaniquement l'amélioration atteignable.

5.4 Limites et perspectives

Le travail est resté limité aux problèmes unidimensionnels, scalaires et d'Euler, et aux schémas d'ordre cinq. Trois prolongements naturels se dégagent :

— **Extension à WENO7/TENO7 et à la 2D.** La pile différentiable et le mécanisme de mélange convexe sont indépendants de l'ordre et de la dimension ; leur extension est essentiellement un travail d'ingénierie.

— **Réduction du coût d'inférence.** Le surcoût actuel vient d'une implémentation non optimisée ; une distillation vers un réseau plus petit, ou une compilation dédiée, sont des pistes directes.
— **Compréhension de l'asymétrie Sod / Shu–Osher.** Identifier quelle caractéristique de l'écoulement rend le mélange bénéfique dans un cas et nuisible dans l'autre serait le prolongement scientifiquement le plus utile, et permettrait peut-être de conditionner λ sur cette caractéristique.

Conclusion

Ce stage avait pour objectif de déterminer si un réseau de neurones peut améliorer un schéma numérique classique de capture de chocs, mesuré strictement contre la solution vraie. La réponse obtenue est nuancée mais positive, et elle tient surtout à *la façon* dont le réseau est entraîné.

Les deux premiers volets, fondés sur l'entraînement par imitation, aboutissent à une égalité : reproduire les résultats publiés de WENO5-NN confirme leur caractère fortement dépendant du problème, et étendre l'approche à TENO5 met en évidence un plafond structurel – un réseau qui copie un enseignant ne peut pas le dépasser. Ce résultat négatif a été le point de bascule du stage.

Les deux volets suivants, fondés sur la fonction de perte physique déroulée proposée par l'encadrant, franchissent ce plafond. Ils ont exigé une réécriture complète et différentiable du cœur numérique en JAX, sans laquelle la proposition n'était pas testable. Ils aboutissent à des victoires vérifiées sur les benchmarks canoniques scalaires ($3{,}5\%$ sur l'advection, $18{,}6\%$ sur Burgers hors distribution) et à une première victoire franche sur le système d'Euler ($1{,}84\%$ sur Shu–Osher), obtenue via une tête de mélange convexe dédiée. Le cas de Sod reste défavorable, et un balayage direct du coefficient de mélange établit qu'il s'agit d'une limite structurelle du schéma appris.

Sur le plan personnel, ce stage a été formateur d'abord par sa discipline expérimentale. Les résultats les plus utiles n'ont pas été les victoires, mais les diagnostics : comprendre pourquoi augmenter la dissipation aggravait l'instabilité a mené à un terme de perte structurellement inerte ; comprendre pourquoi le réseau plafonnait a mené au changement de paradigme d'entraînement. J'ai aussi appris à traiter un résultat négatif comme une donnée à documenter plutôt que comme un échec à masquer – c'est ce qui a rendu la progression mesurable, et c'est la compétence que je retire le plus nettement de ces deux mois.

Références bibliographiques

[1] A. Harten, B. Engquist, S. Osher, S. R. Chakravarthy. *Uniformly high order accurate essentially non-oscillatory schemes, III*. Journal of Computational Physics, 71(2) :231–303, 1987.

[2] C.-W. Shu, S. Osher. *Efficient implementation of essentially non-oscillatory shock-capturing schemes*. Journal of Computational Physics, 77(2) :439–471, 1988.

[3] G.-S. Jiang, C.-W. Shu. *Efficient implementation of weighted ENO schemes*. Journal of Computational Physics, 126(1) :202–228, 1996.

[4] R. Borges, M. Carmona, B. Costa, W. S. Don. *An improved weighted essentially non-oscillatory scheme for hyperbolic conservation laws*. Journal of Computational Physics, 227(6) :3191–3211, 2008.

[5] L. Fu, X. Y. Hu, N. A. Adams. *A family of high-order targeted ENO schemes for compressible-fluid simulations*. Journal of Computational Physics, 305 :333–359, 2016.

[6] B. Stevens, T. Colonius. *Enhancement of shock-capturing methods via machine learning*. Theoretical and Computational Fluid Dynamics, 34 :483–496, 2020.

[7] Y. Li, L. Fu, N. A. Adams. *A six-point neuron-based ENO (NENO6) scheme for compressible fluid dynamics*. arXiv :2207.08500, 2022.

[8] X. Wen, W. S. Don, Z. Gao, J. S. Hesthaven. *An edge detector based on artificial neural network with application to hybrid Compact-WENO finite difference scheme*. Journal of Scientific Computing, 83(49), 2020.

[9] G. A. Sod. *A survey of several finite difference methods for systems of nonlinear hyperbolic conservation laws*. Journal of Computational Physics, 27(1) :1–31, 1978.

[10] J. Bradbury, R. Frostig, P. Hawkins, et al. *JAX : composable transformations of Python+NumPy programs*. `http://github.com/google/jax`, 2018.

[11] L. Weinstein / NASA. *Schlieren photograph of T-38 shock waves* (Mach 1,1, 13 000 pieds). NASA Dryden Flight Research Center Photo Collection, photo EC94-42528-1, 13 décembre 1993. Domaine public (œuvre du gouvernement des États-Unis). Disponible sur Wikimedia Commons : `https://commons.wikimedia.org/wiki/File:Schlieren_photograph_of_T-38_shock_waves.jpg`

Schémas de capture de chocs augmentés par apprentissage automatique

Ce rapport étudie si un réseau de neurones peut améliorer la reconstruction d'un schéma numérique classique de capture de chocs (WENO5, TENO5) pour les lois de conservation hyperboliques, évalué strictement contre la solution vraie sur des benchmarks canoniques.

Le travail établit d'abord un plafond structurel : un réseau entraîné à imiter la décision d'un schéma enseignant ne peut pas le dépasser. Il franchit ensuite ce plafond au moyen d'une fonction de perte physique déroulée, qui évalue le réseau après K pas de simulation réels contre la solution vraie – une formulation qui a exigé une réécriture complète et différentiable du solveur en JAX. Le résultat est une victoire vérifiée sur les benchmarks scalaires canoniques et une première victoire franche sur le système d'Euler.

Mots-clés : WENO, TENO, capture de chocs, lois de conservation, apprentissage profond, différentiation automatique, JAX, système d'Euler.

Université Mohammed VI Polytechnique – College of Computing
Année universitaire 2025–2026