Université Mohammed VI Polytechnique
College of Computing – Benguerir
Filière : Intelligence Artificielle & Data Science

RAPPORT DE STAGE

Projet de Fin d'Année 1 (PFA1)

Conception et développement d'un pipeline d'extraction automatique de documents d'identité français par vision et OCR

Réalisé au sein de

ZIWIG BIOTECH

Du 8 juin au 14 août 2026

Réalisé par :

Alae EL MAHDAOUI

Encadrant professionnel :

M. Achraf ZBAIDA

Encadrant académique :

M. Zaid Hadach

Année universitaire 2025 – 2026

Remerciements

Je tiens à exprimer ma sincère gratitude à l'ensemble des personnes qui ont contribué au bon déroulement de ce stage.

Je remercie tout particulièrement M. Achraf Zbaida, mon encadrant au sein de Ziwig Biotech, pour la confiance qu'il m'a accordée en me confiant un projet à fort enjeu opérationnel, pour la clarté de ses retours techniques et pour la liberté d'initiative qu'il m'a laissée tout au long de ces dix semaines.

Je remercie également le corps professoral et l'administration du College of Computing de l'Université Mohammed VI Polytechnique pour la formation reçue, ainsi que mon encadrant académique pour son suivi et ses conseils lors de la rédaction de ce rapport.

Résumé

Ce rapport présente le travail réalisé lors de mon stage de fin d'année (PFA1) au sein de Ziwig Biotech, entreprise de biotechnologie spécialisée dans le diagnostic médical par analyse de l'ARN salivaire et intelligence artificielle. La mission a consisté à concevoir et développer un pipeline complet d'extraction automatique d'informations à partir de documents d'identité français, destiné à remplacer la saisie manuelle lors de l'inscription des professionnels de santé sur la plateforme numérique de l'entreprise.

La solution développée traite trois familles de documents (Carte Nationale d'Identité, Carte de Professionnel de Santé, Passeport) déclinées en huit sous-types, et s'articule en dix étapes : contrôle qualité de l'image, détection du document par YOLOv8-OBB, correction de perspective, reconnaissance optique de caractères par PaddleOCR, classification du type de document par MobileNetV3-Small avec repli sur une heuristique OCR, détection du sous-type par appariement flou, extraction structurée des champs par LayoutLMv3, récupération et normalisation des valeurs, puis validation finale des valeurs des champs. L'ensemble est exposé via une API REST FastAPI comportant huit points d'entrée.

Les modèles atteignent respectivement un mAP50-95 de 0,987 pour la détection et une exactitude de 99,52 % pour la classification comme pour l'extraction. Sur photographies réelles, le pipeline extrait entre 5/5 et 14/15 champs selon le type de document.

Mots-clés : vision par ordinateur, OCR, extraction d'information documentaire, YOLO, LayoutLMv3, MRZ, FastAPI, données synthétiques.

Table des matières

Remerciements i

Résumé i

Table des matières iii

Liste des figures iii

Liste des tableaux iv

Liste des acronymes iv

Introduction 1

1 Présentation de l'entreprise 1
- 1.1 Domaine d'activité . . . 1
- 1.2 Structure organisationnelle . . . 1
- 1.3 Métiers présents . . . 2

2 Contexte du projet et méthodologie 3
- 2.1 Contexte métier et problématique . . . 3
- 2.2 Périmètre fonctionnel . . . 3
- 2.3 Contraintes . . . 4
- 2.4 Méthodologie et organisation du travail . . . 5
- 2.5 Environnement technique . . . 6

3 Conception de la solution 7
- 3.1 Architecture générale . . . 7
- 3.2 Choix des modèles . . . 7
  - 3.2.1 Détection : YOLOv8-OBB . . . 8
  - 3.2.2 Classification : MobileNetV3-Small . . . 8
  - 3.2.3 Extraction : LayoutLMv3 . . . 9
- 3.3 Configuration déclarative par fichiers YAML . . . 9
- 3.4 Architecture à deux environnements . . . 9

4 Réalisation du pipeline 10
- 4.1 Génération du corpus synthétique . . . 10
- 4.2 Étape 1 – Contrôle qualité . . . 11
- 4.3 Étape 2 – Détection du document . . . 11
- 4.4 Étape 3 – Correction de perspective . . . 12
- 4.5 Étape 4 – Reconnaissance optique de caractères . . . 12
- 4.6 Étape 5 – Classification du type de document . . . 13

4.6.1 Repli par analyse OCR . . . 13
4.7 Étape 6 – Détection du sous-type . . . 14
4.8 Étape 7 – Extraction structurée par LayoutLMv3 . . . 14
4.8.1 Préparation du corpus . . . 14
4.9 Étape 8 – Récupération des champs . . . 15
4.10 Étape 9 – Post-traitement . . . 16
4.11 Étape 10 – Validation . . . 17

5 Exposition par API et résultats **18**
5.1 L'API FastAPI . . . 18
5.2 Résultats obtenus . . . 20
5.3 Analyse critique . . . 20

Conclusion **21**

Références bibliographiques **22**
Ressources open-source consultées . . . 23

Table des figures

2.1 Exemples des types de documents traités par le pipeline (spécimens), utilisés aussi comme templates pour la génération sythétique (CNI) . . . 4
2.2 Exemples des types de documents traités par le pipeline (spécimens), utilisés aussi comme templates pour la génération sythétique (CPS, Passeport) . . . 4

3.1 Architecture générale du pipeline d'extraction en dix étapes . . . 7

4.1 Exemples d'images synthétiques générées (p1) . . . 10
4.2 Exemples d'images synthétiques générées (p2) . . . 11
4.3 Détection du document par YOLOv8-OBB : boîte orientée et coins détectés . . . 12
4.4 Comparaison de quelques méthodes de prétraitement d'OCR. . . . 13
4.5 Champs détectés par l'extraction de LayoutLMv3 (Passeport) . . . 15
4.6 Champs détectés par l'extraction de LayoutLMv3 (CIN) . . . 15
4.7 Structure d'une zone MRZ au format TD3 et champs encodés. L'exemple est fictif ; les chiffres de contrôle ont été calculés conformément à la norme . . . 17

5.1 Interface Swagger de documentation interactive de l'API . . . 19
5.2 Exemple de résultat complet : document en entrée et champs extraits . . . 19

Liste des tableaux

2.1 Périmètre documentaire du pipeline . . . 3
2.2 Planning prévisionnel et réalisé du stage . . . 5
2.3 Technologies et outils utilisés . . . 6

3.1 Synthèse du benchmark préalable et arbitrages retenus . . . 8
3.2 Comparaison des architectures de classification . . . 8

4.1 Critères de contrôle qualité de l'image d'entrée . . . 11
4.2 Performances du détecteur YOLOv8-OBB . . . 12
4.3 Performances du classifieur MobileNetV3-Small . . . 13
4.4 Mots-clés discriminants utilisés par le repli de classification . . . 14
4.5 Hyperparamètres et performances du fine-tuning de LayoutLMv3 . . . 14
4.6 Formats MRZ pris en charge . . . 16
4.7 Principales fonctions de normalisation du post-traitement . . . 16
4.8 Champs vérifiés par somme de contrôle selon le format MRZ . . . 17

5.1 Points d'entrée de l'API . . . 18
5.2 Synthèse des performances des modèles . . . 20
5.3 Qualité d'extraction sur photographies réelles . . . 20

Liste des acronymes

Acronyme	Signification
API	*Application Programming Interface*
BIO	*Begin – Inside – Outside* (schéma d'étiquetage de séquences)
CNI	Carte Nationale d'Identité
CPS	Carte de Professionnel de Santé
FINESS	Fichier National des Établissements Sanitaires et Sociaux
ICAO	*International Civil Aviation Organization*
IA	Intelligence Artificielle
mAP	*mean Average Precision*
MRZ	*Machine Readable Zone*
NGS	*Next-Generation Sequencing*
OBB	*Oriented Bounding Box*
OCR	*Optical Character Recognition*
PFA	Projet de Fin d'Année
RGPD	Règlement Général sur la Protection des Données
RPPS	Répertoire Partagé des Professionnels de Santé
YAML	*YAML Ain't Markup Language*

Introduction

Dans le cadre de ma première année du cycle ingénieur au College of Computing de l'Université Mohammed VI Polytechnique, spécialité Intelligence Artificielle et Science des Données, j'ai effectué un stage de fin d'année (PFA1) d'une durée de dix semaines, du 8 juin au 14 août 2026, au sein de l'entreprise de biotechnologie Ziwig Biotech.

Ziwig développe des solutions de diagnostic médical fondées sur l'analyse de l'ARN salivaire et l'intelligence artificielle. Son activité repose sur une plateforme numérique qui met en relation les patientes et les professionnels de santé prescripteurs. L'inscription de ces professionnels sur la plateforme nécessite la vérification de leur identité et de leur qualité professionnelle à partir de pièces justificatives téléversées. Cette opération, réalisée manuellement, est coûteuse en temps et sujette aux erreurs de transcription.

La mission qui m'a été confiée a consisté à concevoir et développer un pipeline capable d'extraire automatiquement, à partir d'une simple photographie, les informations pertinents d'un document d'identité français, puis de les valider. La problématique peut se formuler ainsi : *comment extraire de façon fiable des informations structurées à partir de photographies de documents d'identité prises en conditions non contrôlées, sans disposer de données réelles annotées pour l'entraînement ?*

Trois difficultés principales en découlent : l'hétérogénéité et diversité des conditions de prise de vue (inclinaison, arrière-plans variables, éclairage inégal, flou) ; les contraintes liées à l'utilisation de documents d'identité contenant des données personnelles, au titre du RGPD, qui ont conduit à privilégier la génération de données synthétiques et à considérer Le problème du décalage de domaine *domain gap* ; enfin l'exigence de fiabilité, une donnée mal extraite mais présentée comme valide étant plus problématique qu'une donnée signalée comme incertaine ou manquante.

Ce rapport s'organise en cinq chapitres : présentation de l'entreprise d'accueil ; contexte, objectifs et méthodologie du projet ; conception de la solution ; réalisation détaillée du pipeline ; enfin, analyse des résultats et bilan de l'expérience acquise.

Chapitre 1

Présentation de l'entreprise

1.1 Domaine d'activité

Ziwig Biotech est une entreprise de biotechnologie fondée par Yahya El Mir. Elle développe des solutions de diagnostic médical fondées sur l'analyse de l'ARN salivaire et l'intelligence artificielle. Son activité s'est notamment développée autour de l'**Endotest**, un test salivaire destiné à contribuer au diagnostic de l'endométriose, avec une ouverture progressive vers d'autres pathologies.

L'entreprise associe ainsi des compétences en biologie moléculaire, en séquençage de nouvelle génération (NGS) et en intelligence artificielle afin de développer des solutions de médecine de précision.

1.2 Structure organisationnelle

Ziwig est une entreprise à taille humaine regroupant plusieurs pôles complémentaires : recherche et développement, biologie moléculaire, intelligence artificielle et data science, numérique, ainsi que les fonctions médicales, réglementaires et opérationnelles.

Le stage s'est déroulé au sein du pôle numérique, chargé notamment du développement des plateformes digitales de l'entreprise. Mon travail s'est ainsi concentré sur la conception d'une solution logicielle d'automatisation du traitement des documents d'identité des utilisateurs de la plateforme.

1.3 Métiers présents

La diversité des activités de Ziwig mobilise des profils issus de la biologie, de la recherche, de la data science, de l'intelligence artificielle, du développement logiciel et des affaires médicales et réglementaires. Cette pluridisciplinarité permet de faire collaborer les compétences scientifiques et technologiques nécessaires au développement des solutions de l'entreprise.

Le projet réalisé durant ce stage s'inscrit principalement à l'intersection de l'intelligence artificielle, de la vision par ordinateur et de l'ingénierie logicielle.

Chapitre 2

Contexte du projet et méthodologie

2.1 Contexte métier et problématique

La plateforme numérique de Ziwig permet aux professionnels de santé de prescrire l'Endotest et d'assurer le suivi de leurs patientes. Leur inscription requiert la vérification de leur identité et de leur qualité professionnelle, à partir de pièces justificatives, notamment une carte nationale d'identité ou passeport, ainsi qu'une carte de professionnel de santé.

Ces informations étaient saisies manuellement, ce qui présente trois limites :

— **Temps de traitement** : la saisie de dix à quinze champs par dossier necessite une intervention manuelle et donc un opérateur pour chaque inscription.

— **Risque d'erreur** : les erreurs de transcription sur un numéro RPPS ou une date de validité ont des conséquences directes sur la conformité du dossier et la validité des informations renseignées.

— **Friction utilisateur** : le traitement manuel peut ralentir le parcours d'inscription et par suite décourager l'utilisateur.

L'objectif du projet est d'automatiser cette étape et donc remplacer cette saisie par le téléversement d'une simple photographie, à partir de laquelle les champs pertinents sont extraits et validés automatiquement avant leur transmission à la plateforme.

2.2 Périmètre fonctionnel

Le périmètre couvre trois familles de documents, déclinées en huit sous-types, chacun présentant une mise en page et des champs distincts (tableau 2.1).

Table 2.1. Périmètre documentaire du pipeline

Type	Sous-types	Principaux champs extraits
CNI recto	Ancienne (pré-2021), Nouvelle (post-2021)	Nom, prénoms, sexe, nationalité, date et lieu de naissance, taille, numéro de carte ou de document, date d'expiration, MRZ
CNI verso	Ancienne, Nouvelle	Adresse, date de délivrance, date d'expiration, autorité, MRZ
CPS	CPS3 (ancienne), CPS4 (nouvelle)	Profession, numéro PSC, nom, prénom, RPPS, FINESS, dates d'émission et d'expiration
Passeport	Ordinaire, Diplomatique	Type, code pays, numéro, nom, prénoms, nationalité, sexe, taille, couleur des yeux, dates, lieu de naissance, autorité, domicile, MRZ



Figure 2.1. Exemples des types de documents traités par le pipeline (spécimens), utilisés aussi comme templates pour la génération sythétique (CNI)



Figure 2.2. Exemples des types de documents traités par le pipeline (spécimens), utilisés aussi comme templates pour la génération sythétique (CPS, Passeport)

2.3 Contraintes

Trois contraintes principales ont orienté l'ensemble des choix techniques du projet.

Contrainte réglementaire. Les documents d'identité constituent des données à caractère personnel au sens du RGPD [11]. Il était donc exclu de constituer un corpus d'entraînement à partir de documents réels. L'entraînement des modèles de classification et d'extraction a par conséquent reposé sur des **données synthétiques générées par programme**, complétées par le jeu public MIDV-500 [2] pour l'étape de détection.

Contrainte de fiabilité. Une valeur incorrecte présentée comme valide est plus problématique qu'une valeur absente. Le pipeline devait donc produire, pour chaque champ, une valeur mais aussi un indicateur de validité et la méthode d'extraction employée, afin de faciliter la vérification humaine.

Contrainte technique. Une incompatibilité entre PaddlePaddle, moteur de PaddleOCR, et les versions de PyTorch nécessaires par les autres modèles a conduit à isoler les dépendances dans deux environnements distincts, architecture décrite davantage au chapitre 3.

2.4 Méthodologie et organisation du travail

Le projet a été developpé de façon **incrémentale** : chaque étape du pipeline a été développée, testée isolément, puis intégrée à la chaîne existante avant de passer à la suivante. Cette approche a permis de disposer à chaque étape d'une version fonctionnelle partielle et de faciliter le diagnostic des erreurs. Le suivi s'était effectué par des points hebdomadaires avec mon encadrant, M. Achraf Zbaida, et par démonstrations sur exemples réels aux étapes principaux du projet (tableau 2.2).

Table 2.2. Planning prévisionnel et réalisé du stage

Semaines	Activités
S1	Prise de connaissance du besoin, cadrage du périmètre, détermination des étapes du pipeline et benchmark technologique comparatif des approches pour le choix du modèle dans chaque étape
S2–S3	Génération des données synthétiques, entraînement du détecteur YOLOv8-OBB, correction de perspective
S4	Intégration de l'OCR, benchmark des méthodes de prétraitement
S5	Entraînement et évaluation du classifieur MobileNetV3, détection des sous-types
S6–S7	Préparation du corpus d'extraction, fine-tuning de LayoutLMv3
S8	Post-traitement, récupération de champs, extraction MRZ
S9	Couche de validation, sommes de contrôle ICAO 9303, cohérence inter-champs
S10	Développement de l'API FastAPI, tests de bout en bout, documentation

2.5 Environnement technique

Le tableau 2.3 récapitule les technologies utilisées.

Table 2.3. Technologies et outils utilisés

Catégorie	Outils
Langage	Python 3.10 (environnement principal), Python 3.9 (environnement OCR)
Vision	Ultralytics YOLOv8-OBB [1], OpenCV
Classification	PyTorch, MobileNetV3-Small [3]
OCR	PaddleOCR [5] (modèle français)
Extraction	HuggingFace Transformers, LayoutLMv3 [4]
Augmentation	Albumentations [7], Augraphy [8]
Appariement flou	RapidFuzz [9]
API	FastAPI [10], Uvicorn
Configuration	YAML (PyYAML)
Entraînement	Kaggle, GPU NVIDIA T4
Versionnement	Git / GitHub [13]

Chapitre 3

Conception de la solution

3.1 Architecture générale

La solution se présente comme une chaîne de traitement en dix étapes, allant de la photographie brute au document JSON structuré et validé. Chaque étape est encapsulée dans un module indépendant, exposé à la fois comme fonction Python et comme point d'entrée de l'API, ce qui facilite le diagnostic : en cas d'échec, il est possible d'identifier précisément l'étape défaillante.

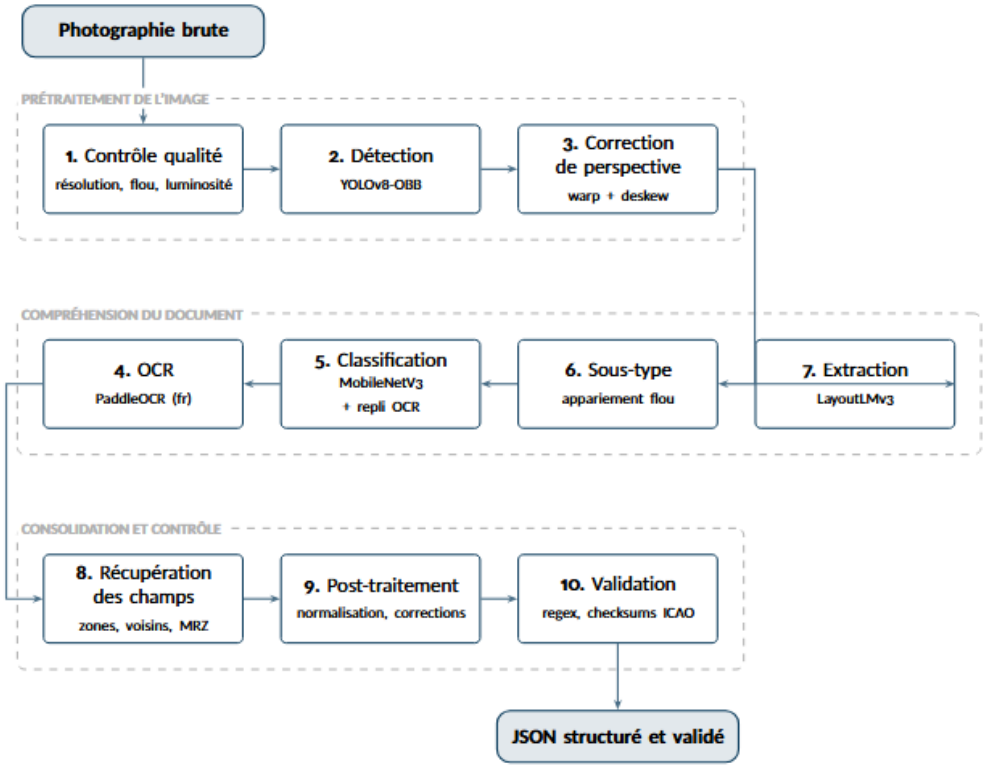


Figure 3.1. Architecture générale du pipeline d'extraction en dix étapes

L'image est d'abord contrôlée en qualité, puis le document est localisé et redressé ; l'OCR fournit ensuite les tokens textuels et leurs positions, qui alimentent simultanément la classification et l'extraction structurée ; les valeurs brutes sont enfin normalisées puis validées.

Un choix de conception mérite d'être souligné : **l'OCR est exécuté avant la classification**. Cette disposition permet de réutiliser le même résultat OCR pour trois usages distincts : le repli de classification, la détection du sous-type et l'extraction par LayoutLMv3 et évite ainsi trois exécutions redondantes d'une étape coûteuse.

3.2 Choix des modèles

Les modèles retenus ne l'ont pas été a priori : la première semaine du stage a été consacrée à un benchmark comparatif couvrant chaque étape du pipeline, dont les conclusions ont été remises à mon encadrant sous

la forme d'un rapport dédié (disponible dans le repo Github du projet [13] [14]). Une vingtaine d'approches y ont été évaluées sur quatre critères : la précision sur documents réels, le temps d'inférence sur CPU, la taille du modèle et la nécessité d'un fine-tuning. Le tableau 3.1 en résume ceci.

Table 3.1. Synthèse du benchmark préalable et arbitrages retenus

Étape	Retenu	Alternatives écartées et motif
Détection	YOLOv8	EasyOCR, RT-DETR-L (4,07 s sur CPU, 63 Mo), contours OpenCV (fiable sur 1 image testée sur 10), Grounding DINO (trop lourd). Aucun modèle pré-entraîné ne détecte un document d'identité sans fine-tuning.
OCR	PaddleOCR	EasyOCR (80 s), Tesseract (texte fragmenté), TrOCR (305 s), DocTR (retenu comme solution de repli). PaddleOCR : 5,82 s et bruit résiduel minimal.
Classification	MobileNetV3	CLIP zero-shot (confond passeport et CNI), EfficientNet-B0 (marges entre classes trop faibles), ResNet-18 (44,7 Mo contre 9,83 Mo).
Extraction	LayoutLMv3	Donut (28,9 s sur CPU, 800 Mo), OCR + LLM (sensible au bruit OCR, résultats non déterministes), segmentation par zones (annotation trop coûteuse par type de document).

Ce benchmark a également orienté deux décisions d'architecture décrites plus loin : le recours à une approche hybride pour la classification, associant un modèle appris à une heuristique textuelle, et un post-traitement dédié à la normalisation des valeurs, vu le grand nombre d'erreurs observées relevant du modèle d'OCR.

Des solutions industrielles proposent des modèles d'extraction prêts à l'emploi pour les documents d'identité [18], et des jeux de données annotés spécifiques aux cartes françaises sont disponibles publiquement [19]. Ces ressources ont servi de points de comparaison lors du cadrage, sans être retenues : la première pour des raisons de dépendance à un service externe dans un contexte de données de santé, la seconde pour son volume limité.

3.2.1 Détection : YOLOv8-OBB

Un détecteur à boîtes orientées (*Oriented Bounding Box*) a été préféré à un détecteur à boîtes alignées sur les axes. En effet, les photographies peuvent être prises avec une certaine inclinaison : une boîte alignée engloberait alors davantage d'arrière-plan et ne fournirait pas précisément les quatre coins du document, nécessaires à la correction de perspective.

3.2.2 Classification : MobileNetV3-Small

MobileNetV3-Small a été retenu après comparaison avec EfficientNet-B0. À exactitude équivalente, MobileNetV3 s'exécute en 4,85 ms par image contre 7,51 ms, soit un gain de 35 % sur une étape appelée pour chaque document(tableau 3.2).

Table 3.2. Comparaison des architectures de classification

Modèle	Exactitude (test)	Temps d'inférence
MobileNetV3-Small	99,52 %	4,85 ms/image
EfficientNet-B0	équivalente	7,51 ms/image

3.2.3 Extraction : LayoutLMv3

Les modèles de langue classiques traitent un document comme une séquence linéaire de mots et ne tiennent pas compte de leur disposition spatiale. Or, dans un document d'identité, la position d'un mot est importante pour déterminer son rôle : c'est sa localisation sous l'intitulé « Nom » qui identifie un mot comme patronyme. LayoutLMv3 combine l'image du document, les tokens OCR et leurs coordonnées, ce qui le rend adapté à l'extraction d'informations dans des documents à structure fixe.

3.3 Configuration déclarative par fichiers YAML

Plutôt que de coder en dur les particularités de chacun des huit sous-types, j'ai adopté une approche déclarative : chaque sous-type dispose d'un fichier YAML décrivant ses champs, leur caractère obligatoire, leur expression régulière de validation, leur zone de localisation en coordonnées normalisées et leurs relations de voisinage.

Listing 3.1. Extrait de configuration YAML pour la CNI ancienne

```yaml
document_type: cni_recto
sublabel: cni_ancienne
country: FR
language: fr

fields:
  - name: nom
    label: NOM
    required: true
    pattern: "^[A-Z\\s\\-']+$"
    zone:
      x_range: [0.32, 0.68]     # coordonnees normalisees [0,1]
      y_range: [0.19, 0.27]
    neighbors:
      below: NUM_CARTE
      above: PRENOMS

mrz:
  present: true
  lines: 2
  format: TD1
```

L'intérêt est double : le code de traitement reste unique et générique, et l'ajout d'un nouveau type de document, comme un permis de conduire, par exemple, se ramène à la rédaction d'un fichier de configuration.

3.4 Architecture à deux environnements

L'incompatibilité entre PaddlePaddle et PyTorch a été résolue par l'isolement de PaddleOCR dans un environnement Conda dédié, invoqué depuis l'environnement principal par `subprocess`, avec échange de données au format JSON. Cette solution introduit un léger surcoût de latence lié au démarrage du processus, mais garantit la stabilité des deux chaînes de dépendances.

Chapitre 4

Réalisation du pipeline

4.1 Génération du corpus synthétique

L'absence de données réelles annotées, a rendu nécessaire la construction d'un générateur de documents synthétiques reproduisant les caractéristiques visuelles et textuelles des documents français. Les spécimens de base proviennent de PRADO (*Public Register of Authentic identity and travel Documents Online*, Conseil de l'Union européenne) [15], du portail `esante.gouv.fr` pour la CPS, et de Wikimedia Commons ; ce sont ceux présentés aux figures 2.1 et 2.2.

Le générateur, développé avec Pillow et Faker, remplit les zones textuelles de ces spécimens avec des données aléatoires respectant les formats officiels : patronymes issus des répertoires INSEE, numéros RPPS à 11 chiffres, numéros de carte CNI à 12 chiffres, numéros de passeport au format `NNAAANNNN`. Deux familles d'augmentation sont ensuite appliquées :

— **Albumentations** : transformations photométriques et géométriques : rotations ($\pm 15°$), flou gaussien et de mouvement, bruit, compression JPEG (qualité 50 à 95 %), variations colorimétriques.

— **Augraphy** : dégradations physiques du support : bavures d'encre (*InkBleed*), salissures (*DirtyDrum*), plis (*Folding*), vieillissement du papier (*LightingGradient*).

L'apport décisif de cette approche est que le générateur produit **simultanément l'image et ses annotations** : les étiquettes de classe pour le classifieur, ainsi que les coordonnées de chaque champ textuel et leurs valeurs, converties en annotations BIO au niveau du mot (`B-NOM`, `I-NOM`, `O`, etc.) pour LayoutLMv3. Trois cents images ont été générées par type de document, soit 1 200 images au total, réparties en 960 exemples d'entraînement, 120 de validation et 120 de test.



Figure 4.1. Exemples d'images synthétiques générées (p1)

Cette démarche rejoint celle adoptée par le jeu DocXPand-25k [16], qui génère près de 25 000 images de documents d'identité fictifs à partir de templates vectoriels et de la même bibliothèque Faker, confirmant la viabilité de la génération synthétique face aux restrictions d'accès aux données réelles.



Figure 4.2. Exemples d'images synthétiques générées (p2)

Les images produites représentent des documents seuls, bien cadrés et redressés, sans arrière-plan (figure 4.1, 4.2). Ce choix est délibéré : le classifieur et le modèle d'extraction n'interviennent qu'après la détection et la correction de perspective, et reçoivent donc systématiquement des documents déjà recadrés et normalisés. Des spécimens sans arrière-plan reproduisent exactement cette condition d'entrée, tout en simplifiant considérablement la génération, puisqu'il n'est pas nécessaire de simuler un contexte photographique réaliste.

4.2 Étape 1 – Contrôle qualité

Le module de contrôle qualité écarte les images inexploitables avant les étapes suivantes, afin d'éviter des traitements coûteux inutiles. Les critères retenus figurent au tableau 4.1.

Table 4.1. Critères de contrôle qualité de l'image d'entrée

Critère	Méthode	Seuil
Résolution	Dimensions de l'image	min. 400 × 300 px
Flou	Variance du laplacien	min. 80
Luminosité	Moyenne des niveaux de gris	50 – 220
Rapport d'aspect	Largeur / hauteur	0,9 – 2,5
Qualité OCR	Nombre de mots détectés	min. 5 mots

4.3 Étape 2 – Détection du document

Le détecteur YOLOv8-OBB a été entraîné sur le jeu public MIDV-500 [2], qui rassemble 500 types de documents filmés en conditions variées. Les annotations JSON du jeu ont été converties au format YOLO-OBB. Environ 13 % des images présentaient des coordonnées hors bornes, correspondant à des documents partiellement sortis du cadre ; ces coordonnées ont été bornées à l'intervalle $[0, 1]$ plutôt que supprimées, afin de conserver ces situations représentatives des conditions réelles.

Table 4.2. Performances du détecteur YOLOv8-OBB

Métrique	Valeur
mAP50-95	0,987
Précision	1,00
Rappel	1,00

Un mécanisme de repli a été ajouté : lorsque la confiance de détection est inférieure à 0,9, situation typique d'un document occupant la quasi-totalité du cadre, sans marge d'arrière-plan, une bordure blanche est ajoutée à l'image et la détection est relancée.

Le modèle entraîné uniquement sur MIDV-500 ne couvrant pas la Carte de Professionnel de Santé (CPS), un second entraînement a été réalisé sur le corpus synthétique spécifique aux documents du projet, décrit à la section 4.1. Cette adaptation a permis d'améliorer la détection de la CPS et de réduire le recours au mécanisme de padding, conservé comme filet de sécurité.

Une extension ultérieure, MIDV-2020 [17], propose une plus grande diversité d'identités par classe, mais ne couvre pas davantage la CPS.



Figure 4.3. Détection du document par YOLOv8-OBB : boîte orientée et coins détectés

4.4 Étape 3 – Correction de perspective

Les quatre coins fournis par YOLOv8-OBB sont réordonnés selon une convention fixe : supérieur gauche, supérieur droit, inférieur droit et inférieur gauche. Ils sont ensuite associés aux quatre coins d'une image cible afin de calculer une transformation projective (homographie), appliquée avec `cv2.getPerspectiveTransform` et `cv2.warpPerspective`. Les dimensions cibles respectent les proportions normalisées des documents physiques définies par la norme ISO/IEC 7810 : 856 $\times$ 540 px pour les documents au format ID-1 et 1250 $\times$ 880 px pour les passeports au format ID-3. Le respect de ces proportions est important, car les coordonnées des zones de champs sont ensuite définies relativement à l'image. Une correction de rotation résiduelle est enfin appliquée lorsque l'inclinaison dépasse 0,5°. Celle-ci est estimée à partir des contours détectés par Canny et des segments extraits par la transformée de Hough. La rotation est ensuite corrigée par interpolation bicubique, avec réplication des pixels aux bordures.

4.5 Étape 4 – Reconnaissance optique de caractères

PaddleOCR, configuré pour le français, produit pour chaque mot son contenu textuel et sa boîte englobante, normalisée dans l'intervalle $[0, 1000]$ attendu par LayoutLMv3.

La sortie est standardisée en JSON (mots, boîtes brutes, boîtes normalisées, dimensions de l'image). Un banc d'essai comparant sept méthodes de prétraitement a montré qu'un simple agrandissement d'un fac-

teur 2 pour les images de largeur inférieure à 800 px offrait le meilleur compromis, les traitements plus sophistiqués (binarisation adaptative, débruitage) dégradant les résultats sur documents en couleur.



Figure 4.4. Comparaison de quelques méthodes de prétraitement d'OCR.

4.6 Étape 5 – Classification du type de document

Le classifieur distingue quatre classes : `cni_recto`, `cni_verso`, `cps_recto` et `passeport`. Il a été entraîné sur 1 200 images synthétiques (300 par classe), soumises à une double augmentation : transformations photométriques et géométriques via Albumentations, puis dégradations physiques réalistes via Augraphy (bavures d'encre, plis, taches).

Table 4.3. Performances du classifieur MobileNetV3-Small

Métrique	Valeur
Exactitude (validation)	96,83 %
Exactitude (test)	99,52 %
Temps d'inférence	4,85 ms/image

4.6.1 Repli par analyse OCR

Ces résultats ne se transposent pas intégralement aux photographies réelles : les images d'entraînement présentent des arrière-plans uniformes et un cadrage parfait, là où les photographies réelles comportent des arrière-plans variés et un éclairage inégal. En pratique, la confiance du modèle chute sensiblement sur certaines images réelles. Un mécanisme de repli fondé sur des règles a donc été ajouté ; il se déclenche dans deux situations :

1. lorsque la confiance de MobileNetV3 est inférieure à 0,85 ;
2. lorsque, après récupération des champs, plus de 40 % des champs obligatoires demeurent manquants, signe d'une classification initiale probablement erronée.

Le repli recherche dans le texte OCR des mots-clés caractéristiques de chaque type de document à l'aide d'un appariement flou (*fuzzy matching*) avec RapidFuzz. Cette méthode permet de tolérer les erreurs de reconnaissance de caractères. Le score de chaque type correspond à la proportion de mots-clés retrouvés,

avec un seuil de similarité de 70 %. Si aucun type n'atteint 20 % de correspondance, aucune classification n'est retenue, ce qui signale une qualité OCR insuffisante.

Table 4.4. Mots-clés discriminants utilisés par le repli de classification

Type	Exemples de mots-clés
`cni_recto`	« CARTE NATIONALE D'IDENTITE », « IDENTITY CARD », « NOM D'USAGE », « N DU DOCUMENT »
`cni_verso`	« CARTE VALABLE JUSQU'AU », « DELIVREE LE », « SIGNATURE DE L'AUTORITE »
`cps_recto`	« ORDRE NATIONAL DES MEDECINS », « CARTE DE PROFESSIONNEL DE SANTE », « RPPS », « EXPIRE FIN »
`passeport`	« PASSEPORT », « PASSPORT », « COULEUR DES YEUX », « DOMICILE / RESIDENCE »

La méthode effectivement employée (`mobilenetv3` ou `ocr_fallback`) est reportée dans le JSON de sortie, garantissant la traçabilité de la décision.

4.7 Étape 6 – Détection du sous-type

Le sous-type est identifié sur le texte OCR par la même technique d'appariement flou qu'à l'étape précédente, appliquée selon une logique de présence/absence (tandis que dans l'étape précédante 5, le score est agrégé en proportion de mots-clés retrouvés), et cette fois à des indicateurs caractéristiques : la présence des mentions « IDENTITY CARD » et « GIVEN NAMES » distingue la CNI nouvelle de l'ancienne ; l'opposition entre « émise le » et « expire fin » distingue les deux générations de CPS ; la mention « DIPLOMATIQUE » identifie le passeport diplomatique. Le sous-type détermine le fichier YAML chargé pour la suite du traitement.

4.8 Étape 7 – Extraction structurée par LayoutLMv3

4.8.1 Préparation du corpus

La constitution du corpus a représenté la part la plus importante de cette étape. PaddleOCR a été exécuté sur les images synthétiques pour obtenir les tokens individuels, dont les boîtes ont été alignées avec les zones annotées afin de produire des étiquettes BIO au niveau du mot (`B-NOM`, `I-NOM`, `O`, etc.), soit 34 étiquettes distinctes. Le jeu résultant, au format HuggingFace, comporte 960 exemples d'entraînement, 120 de validation et 120 de test.

Table 4.5. Hyperparamètres et performances du fine-tuning de LayoutLMv3

Paramètre	Valeur
Modèle de base	`microsoft/layoutlmv3-base`
Époques	10
Taille de lot	4
Taux d'apprentissage	5×10^{-5}
Matériel	GPU NVIDIA T4 (Kaggle)
Exactitude (validation)	96,83 %
Exactitude (test)	99,52 %

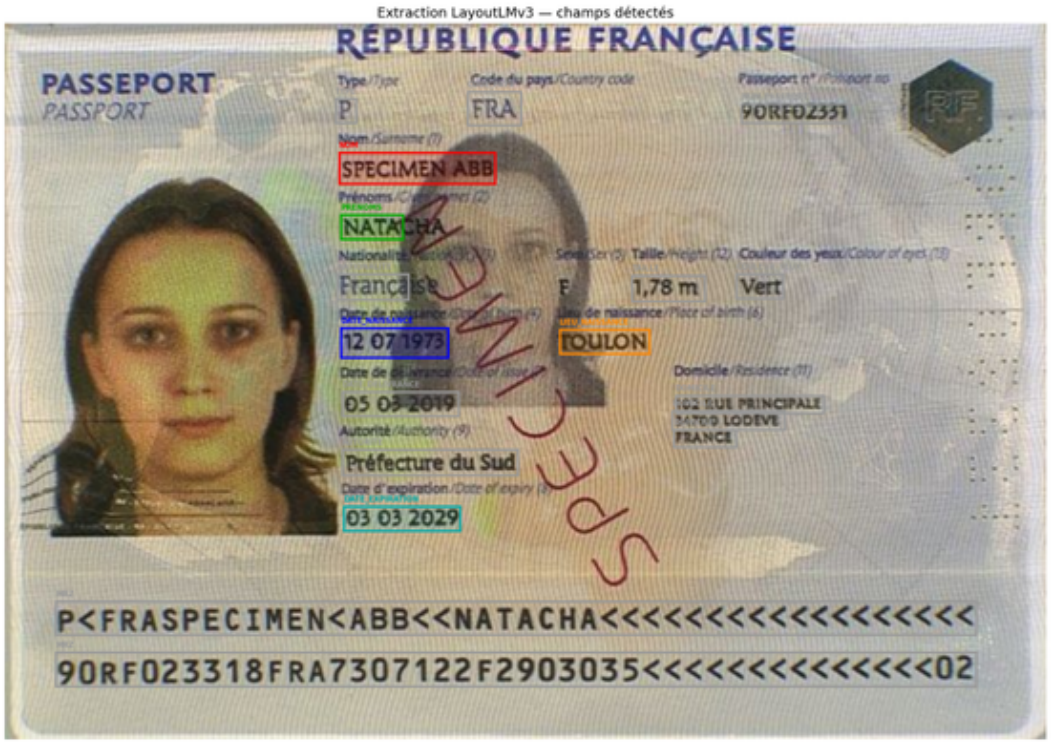


Figure 4.5. Champs détectés par l'extraction de LayoutLMv3 (Passeport)



Figure 4.6. Champs détectés par l'extraction de LayoutLMv3 (CIN)

4.9 Étape 8 – Récupération des champs

Le module de récupération corrige et complète la sortie de LayoutLMv3 selon six mécanismes.

Filtrage par la configuration. L'itération se fait sur les champs déclarés dans le YAML, puisque les clés issues du modèle sont en correspondance avec la nomenclature des fichiers de configuration : tout label prédit mais non défini pour le sous-type courant est ignoré, ce qui élimine les faux positifs.

Récupération par zone. Chaque champ dispose dans le YAML d'une zone rectangulaire en coordonnées normalisées, calibrée sur des photographies réelles. Lorsqu'un champ est manquant, le token OCR dont le centre est le plus proche du centre de la zone est sélectionné.

Récupération par voisinage. Les relations spatiales entre champs (*below*, *above*, *same_row*, *left_of*, *right_of*) déclarées dans la configuration permettent de localiser un champ manquant à partir d'un champ voisin correctement identifié.

Traitement de la zone MRZ. LayoutLMv3 regroupe l'intégralité des lignes MRZ en un unique token. Un découpage à longueur fixe est appliqué selon le format (tableau 4.6).

Table 4.6. Formats MRZ pris en charge

Format	Document	Lignes	Caractères / ligne
TD1 ancienne	CNI ancienne (recto)	2	36
TD1 standard	CNI nouvelle (verso)	3	30
TD3	Passeport	2	44

4.10 Étape 9 – Post-traitement

Les valeurs brutes issues de l'OCR sont rarement exploitables telles quelles : elles incluent les intitulés imprimés, présentent des confusions de caractères et des formats hétérogènes. Le module applique une fonction de normalisation adaptée à chaque type de champ (tableau 4.7).

Table 4.7. Principales fonctions de normalisation du post-traitement

Fonction	Description
`remove_prefixes`	33 motifs d'expressions régulières supprimant les intitulés imprimés accolés (« FNNom : », « Prénom(s) », « Né(e) le », « Taille : »)
`fix_ocr_substitutions`	Correction selon le type de champ : numérique (O→0, I→1), alphabétique (0→O, 1→I)
`normalize_date`	Unification au format `JJ MM AAAA` ; gère les dates agglutinées (01041995) et les années tronquées (196→1960) avec indicateur `inferred`
`normalize_num_passport`	Format `NNAAANNNN`, correction caractère par caractère selon la position
`normalize_lieu`	Extraction du département avant correction, puis appariement flou sur un référentiel de communes (seuil 75 %)
`normalize_taille`	Unification au format `1,XX` ; gère 1M70, 1.78m, 171m, 72m→1,72
`normalize_profession`	Appariement flou sur un référentiel de professions médicales (seuil 70 %)
`normalize_nationalite`	Corrections spécifiques (ERA→FRA, FRANCA→FRA)
`normalize_mrz`	Restriction aux caractères A–Z, 0–9 et « < »

Deux règles de priorité complètent le dispositif : pour la CNI ancienne et le passeport, les champs présents dans la MRZ en sont extraits en priorité, la lecture d'une zone à police monospace normalisée étant plus fiable que celle du texte visuel ; et lorsque recto et verso d'une CNI nouvelle sont fournis conjointement, les données MRZ du verso enrichissent automatiquement le recto (la CNI nouvelle ne portant sa MRZ complète qu'au verso).

Extraction depuis la MRZ. La zone de lecture automatique encode de façon redondante l'essentiel des données : nom, prénoms, numéro de document, date de naissance, date d'expiration, sexe, nationalité et code pays. Ces valeurs sont extraites dans cette étape de post-traitement et constituent une source alternative de haute fiabilité.

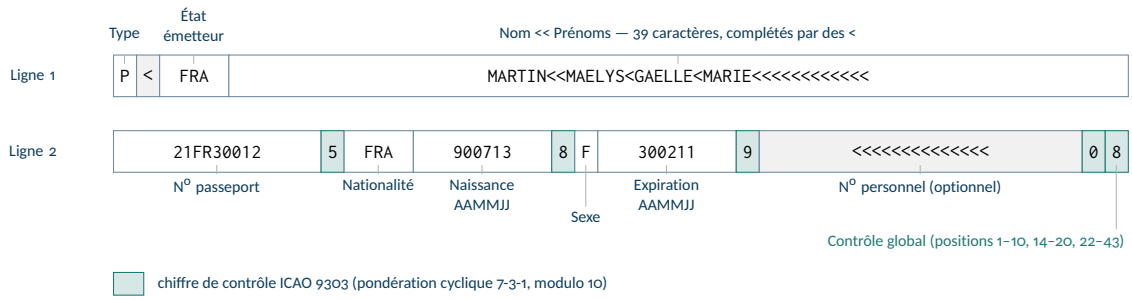


Figure 4.7. Structure d'une zone MRZ au format TD3 et champs encodés. L'exemple est fictif ; les chiffres de contrôle ont été calculés conformément à la norme

4.11 Étape 10 – Validation

La couche de validation constitue la garantie de fiabilité du pipeline. Elle opère à trois niveaux.

Validation par expression régulière. Chaque champ est confronté au motif déclaré dans son YAML. Si la valeur est invalide et provenait de LayoutLMv3, une seconde tentative est effectuée par récupération de zone, suivie d'un nouveau post-traitement. En cas d'échec, le champ est marqué `invalid_after_recovery`.

Sommes de contrôle MRZ. La norme ICAO 9303 [6] définit des chiffres de contrôle calculés selon une pondération cyclique 7-3-1 (A–Z = 10–35, chiffres pour eux-mêmes, 0 pour le caractère de remplissage), le total étant réduit modulo 10. Ces sommes offrent une garantie quasi mathématique sur la lecture de la MRZ : un numéro dont la somme de contrôle est correcte a une probabilité très faible d'avoir été mal reconnu.

Table 4.8. Champs vérifiés par somme de contrôle selon le format MRZ

Format	Champs vérifiés
TD3 (passeport)	Numéro de passeport, date de naissance, date d'expiration, contrôle global
TD1 2 lignes (CNI ancienne)	Numéro de carte, date de naissance
TD1 3 lignes (CNI verso)	Date de naissance, date d'expiration

Cohérence inter-champs. Quatre règles logiques sont appliquées : la date de naissance doit précéder la date d'expiration ; la date de délivrance doit précéder la date d'expiration ; le document ne doit pas être expiré ; l'âge déduit doit être compris entre 0 et 120 ans.

Un statut global est enfin attribué : `valid` lorsque tous les champs obligatoires sont valides et qu'aucune incohérence n'est relevée ; `partial` lorsque moins d'un tiers des champs obligatoires sont invalides ; `invalid` au-delà.

Chapitre 5

Exposition par API et résultats

5.1 L'API FastAPI

Le pipeline est exposé par une API REST FastAPI de huit points d'entrée (tableau 5.1). Exposer chaque étape individuellement, en plus du pipeline complet, répond à un besoin de diagnostic : lorsqu'un document produit un résultat inattendu, l'étape défaillante peut être isolée sans instrumenter le code.

Table 5.1. Points d'entrée de l'API

Méthode	Route	Fonction
GET	`/health`	Vérification de disponibilité
POST	`/detect`	Détection seule : coins, confiance, scores qualité
POST	`/preview`	Détection et redressement : renvoie l'image recadrée
POST	`/classify`	Classification du type de document
POST	`/sublabel`	Détection du sous-type
POST	`/ocr`	Reconnaissance optique seule
POST	`/extract-fields`	Extraction et validation (type et sous-type fournis)
POST	`/extract`	Pipeline complet automatique, 1 à 4 images

Le point d'entrée `/extract` accepte jusqu'à quatre images. Lorsqu'un recto et un verso de CNI nouvelle sont détectés parmi elles, l'enrichissement croisé décrit au chapitre précédent est déclenché automatiquement.

Listing 5.1. Extrait de reponse JSON du point d'entree /extract-fields

```
{
  "document_type": "cni_recto",
  "sublabel": "cni_ancienne",
  "status": "valid",
  "mrz_checksums": {"num_carte": true, "date_naissance": true},
  "cross_field_errors": [],
  "fields": {
    "nom":     {"value": "FAUCHER", "valid": true, "method": "mrz_extraction"},
    "prenoms": {"value": "NICOLAS", "valid": true, "method": "mrz_extraction"},
    "sexe":    {"value": "M",       "valid": true, "method": "mrz_extraction"}
  }
}
```

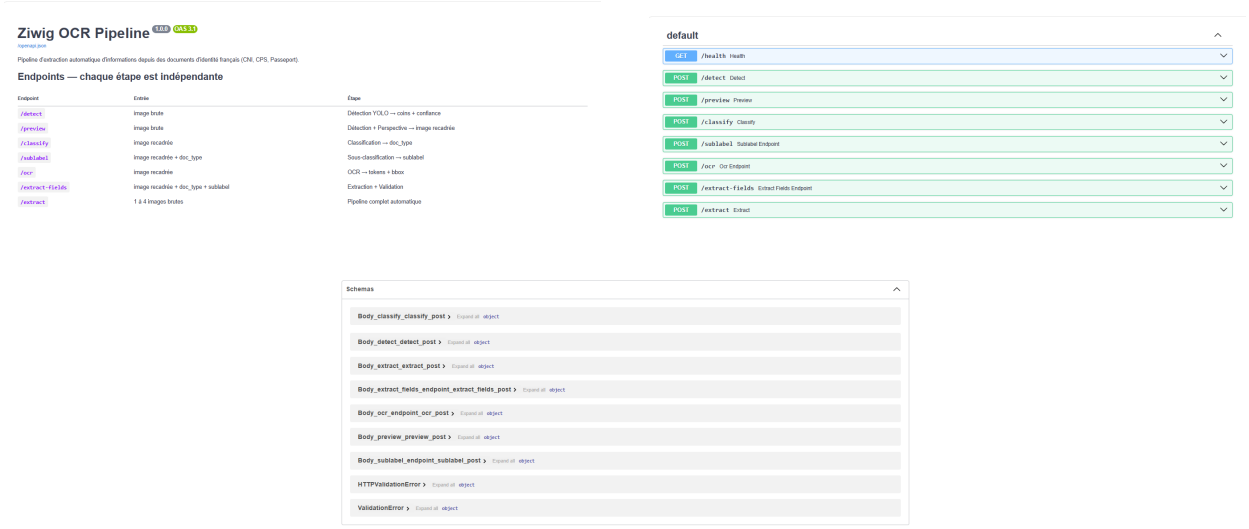


Figure 5.1. Interface Swagger de documentation interactive de l'API



(a) Document en entrée



(b) Champs extraits depuis le endpoint /extract

Figure 5.2. Exemple de résultat complet : document en entrée et champs extraits

5.2 Résultats obtenus

Le tableau 5.2 synthétise les performances des trois modèles entraînés.

Table 5.2. Synthèse des performances des modèles

Modèle	Métrique	Valeur
YOLOv8-OBB	mAP50-95	0,987
MobileNetV3	Exactitude (test)	99,52 %
LayoutLMv3	Exactitude (test)	99,52 %

L'évaluation de bout en bout sur photographies réelles, plus représentative de l'usage effectif, est présentée au tableau 5.3.

Table 5.3. Qualité d'extraction sur photographies réelles

Type de document	Champs extraits	Champs valides
CNI ancienne	8/8	7/8
CNI nouvelle	9/10	8/10
CPS	5/5	5/5
Passeport	14/15	13/15

5.3 Analyse critique

Ces résultats appellent plusieurs réserves méthodologiques qu'il serait malhonnête de passer sous silence.

Le décalage entre données synthétiques et réelles. Les exactitudes de 99,52 % sont mesurées sur des jeux de test issus de la même génération synthétique que les données d'entraînement. Elles témoignent de la capacité des modèles à apprendre la tâche, mais surestiment nettement leur performance en conditions réelles.

Cet ordre de grandeur est cohérent avec la littérature : sur le jeu DocXPand-25k, MobileNetV3-Small atteint 99,65 % sur quinze classes de documents [16]. Ce même travail souligne toutefois que les performances mesurées sur données synthétiques ne préjugent pas du comportement sur images réelles, et intègre pour cette raison près de 5 800 arrière-plans photographiques réels dans son processus de génération, piste que je n'ai pas eu le temps d'explorer.

La taille des échantillons d'évaluation réelle. L'évaluation sur photographies réelles porte sur un nombre limité de documents, ce qui interdit toute conclusion statistique solide. Elle constitue une validation qualitative du pipeline, non une mesure de performance industrielle.

Ces limites n'empêchent pas l'utilisation du pipeline comme aide à la saisie, notamment grâce à la traçabilité des résultats et au signalement des champs douteux. Toutefois, un contrôle humain reste nécessaire pour les informations critiques.

Conclusion

Ce stage de dix semaines au sein de Ziwig Biotech a abouti à la livraison d'un pipeline complet d'extraction automatique de documents d'identité français, opérationnel sur trois familles de documents déclinées en huit sous-types, et exposé par une API REST documentée.

Sur le plan technique, la solution articule quatre modèles : détection par YOLOv8-OBB, reconnaissance optique par PaddleOCR, classification par MobileNetV3-Small et extraction structurée par LayoutLMv3, au sein d'une chaîne complétée par des couches de récupération, de normalisation et de validation. Cette dernière, fondée sur les sommes de contrôle ICAO 9303 et sur des règles de cohérence inter-champs, confère au système sa fiabilité opérationnelle en signalant explicitement les valeurs douteuses.

Sur le plan méthodologique, l'absence de données réelles a orienté le projet vers la génération synthétique et rendu visible le problème du décalage de domaine. La réponse apportée : mécanismes de repli, récupération par zone et par voisinage, priorité accordée à la MRZ, illustre une approche où la robustesse résulte davantage de la redondance des sources d'information que de la performance d'un modèle isolé.

Plusieurs axes d'amélioration se dégagent. À court terme, l'enrichissement de la génération synthétique : arrière-plans variés, exploitation de modèles de diffusion, *hard example mining*, et l'intégration d'un ensemble réduit de photographies réelles anonymisées permettraient de réduire le décalage de domaine [16]. À moyen terme, la détection de falsification et l'anonymisation automatique des données sensibles. À plus long terme, une interface de supervision, la prise en charge de nouveaux documents (permis de conduire, titre de séjour) et une conteneurisation Docker pour le déploiement en production complèteraient le dispositif.

Au-delà des compétences en vision par ordinateur, modèles multimodaux, traitement documentaire et génération de données, ce projet m'a permis de développer des compétences en ingénierie logicielle à travers la conception d'une architecture modulaire, la gestion des dépendances et le développement d'une API. Il m'a également appris à mieux appréhender l'écart entre les performances mesurées sur un jeu de test et le comportement réel d'un système, ainsi que l'importance des mécanismes de repli, de la validation et de la documentation dans une application destinée à la production.

Cette expérience m'a ainsi permis de mieux comprendre que la réalisation d'un système fiable ne repose pas uniquement sur la performance des modèles, mais sur l'intégration cohérente de l'ensemble de la chaîne, de la préparation des données jusqu'à la validation des résultats.

Bibliographie

[1] Jocher, G., Chaurasia, A., Qiu, J. *Ultralytics YOLOv8*. 2023. https://github.com/ultralytics/ultralytics

[2] Arlazarov, V. V., Bulatov, K., Chernov, T., Arlazarov, V. L. *MIDV-500 : A Dataset for Identity Document Analysis and Recognition on Mobile Devices in Video Stream*. Computer Optics, vol. 43, n° 5, 2019, p. 818–824.

[3] Howard, A. *et al*. *Searching for MobileNetV3*. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2019.

[4] Huang, Y., Lv, T., Cui, L., Lu, Y., Wei, F. *LayoutLMv3 : Pre-training for Document AI with Unified Text and Image Masking*. Proceedings of the 30th ACM International Conference on Multimedia, 2022.

[5] PaddlePaddle Authors. *PaddleOCR : Awesome Multilingual OCR Toolkits based on PaddlePaddle*. 2020. https://github.com/PaddlePaddle/PaddleOCR

[6] International Civil Aviation Organization. *Doc 9303 — Machine Readable Travel Documents*, 8e édition, 2021.

[7] Buslaev, A. *et al*. *Albumentations : Fast and Flexible Image Augmentations*. Information, vol. 11, n° 2, 2020.

[8] The Augraphy Project. *Augraphy : Augmentation Pipeline for Rendering Synthetic Paper Printing, Faxing, Scanning and Copy Machine Processes*. 2023. https://github.com/sparkfish/augraphy

[9] Bachmann, M. *RapidFuzz : Rapid Fuzzy String Matching in Python*. 2021. https://github.com/rapidfuzz/RapidFuzz

[10] Ramírez, S. *FastAPI Documentation*. https://fastapi.tiangolo.com

[11] Parlement européen et Conseil de l'Union européenne. *Règlement (UE) 2016/679 relatif à la protection des personnes physiques à l'égard du traitement des données à caractère personnel* (RGPD). 27 avril 2016.

[12] Ziwig Biotech. *Site institutionnel*. https://www.ziwig.com

[13] El Mahdaoui, A. *identity-docs-validation — Pipeline OCR d'extraction de documents d'identité français*. 2026. https://github.com/alaeelmahdaoui01/identity-docs-validation

[14] El Mahdaoui, A. *Rapport de benchmark — Pipeline OCR, documents d'identité*. Document interne, Ziwig Biotech, 11 juin 2026.

[15] Conseil de l'Union européenne. *PRADO — Registre public en ligne de documents d'identité et de voyage authentiques*. https://www.consilium.europa.eu/prado/

[16] Lerouge, J., Betmont, G., Bres, T., Stepankevich, E., Bergès, A. *DocXPand-25k : a large and diverse benchmark dataset for identity documents analysis*. QuickSign, arXiv :2407.20662, 2024. Code et jeu de données : https://github.com/QuickSign/docxpand

[17] Bulatov, K., Emelianova, E., Tropin, D. *et al*. *MIDV-2020 : A comprehensive benchmark dataset for identity document analysis*. Computer Optics, vol. 46, n° 2, 2022, p. 252–270.

[18] Mindee. *International ID Card — Extraction models documentation*. https://docs.mindee.com/use-cases/extraction-models/international-id-card

[19] *French Card ID Detect — jeu de données annoté pour la détection de cartes d'identité françaises*. Roboflow Universe. https://universe.roboflow.com/id-card-labl-zvqce/french-card-id-detect

Ressources open-source consultées

Plusieurs implémentations open-source d'extraction de documents d'identité ont été examinées lors du cadrage, sans être reprises directement : `github.com/tailtq/identity-card-info-extraction`, `github.com/Zer0-Bug/ID-Document_Recognition` et `github.com/Lal4Tech/OCR-Identity-Cards`.

Pipeline d'extraction automatique de documents d'identité français

Rapport de stage PFA1 — Alae El Mahdaoui

Résumé

Ce rapport rend compte d'un stage de dix semaines effectué au sein de Ziwig Biotech, entreprise française de biotechnologie spécialisée dans le diagnostic de l'endométriose par analyse de l'ARN salivaire et intelligence artificielle. La mission a porté sur la conception et le développement d'un pipeline d'extraction automatique d'informations à partir de photographies de documents d'identité français, destiné à remplacer la saisie manuelle lors de l'inscription des professionnels de santé sur la plateforme de l'entreprise. La solution couvre trois familles de documents en huit sous-types et enchaîne neuf traitements : contrôle qualité, détection par YOLOv8-OBB, correction de perspective, reconnaissance optique par PaddleOCR, classification par MobileNetV3 avec repli heuristique, détection du sous-type, extraction structurée par LayoutLMv3, récupération et normalisation des champs, puis validation par expressions régulières, sommes de contrôle MRZ (ICAO 9303) et règles de cohérence. Le tout est exposé par une API REST FastAPI de huit points d'entrée. L'absence de données réelles, imposée par le RGPD, a conduit à un entraînement sur données synthétiques et à la mise en place de mécanismes de redondance destinés à compenser le décalage de domaine.

Mots-clés : vision par ordinateur, OCR, extraction d'information documentaire, YOLO, LayoutLMv3, MRZ, FastAPI, données synthétiques, RGPD.

Abstract

This report describes a ten-week internship at Ziwig Biotech, a French biotechnology company specialising in the diagnosis of endometriosis through salivary RNA analysis and artificial intelligence. The assignment consisted in designing and developing an automatic information-extraction pipeline for photographs of French identity documents, intended to replace manual data entry during the registration of healthcare professionals on the company's platform. The solution covers three document families across eight subtypes and chains nine processing stages: quality control, YOLOv8-OBB detection, perspective correction, PaddleOCR text recognition, MobileNetV3 classification with heuristic fallback, subtype detection, structured extraction with LayoutLMv3, field recovery and normalisation, and final validation through regular expressions, MRZ checksums (ICAO 9303) and cross-field consistency rules. The pipeline is exposed through an eight-endpoint FastAPI REST service. The absence of real training data, mandated by GDPR, led to synthetic-data training and to redundancy mechanisms designed to mitigate the resulting domain gap.

Keywords: computer vision, OCR, document information extraction, YOLO, LayoutLMv3, MRZ, FastAPI, synthetic data, GDPR.

Université Mohammed VI Polytechnique – College of Computing, Benguerir
Filière Intelligence Artificielle & Science des Données – Année universitaire 2025–2026